



UNIVERSIDAD
NACIONAL
DE COLOMBIA

DEPARTAMENTO DE ESTADÍSTICA
SERIES DE TIEMPO UNIVARIADAS
PROYECTO
08 DE MARZO - 2025

Jhon Alejandro Ramírez Daza
Javier Felipe Rodríguez Ardila
Juan Felipe Moreno Rodríguez
Brad Dereck Roza Rubio

jramirezda@unal.edu.co
jarodriguezar@unal.edu.co
jmorenorod@unal.edu.co
brozo@unal.edu.co

1. Descripción de los datos

Colombia se destaca como uno de los mayores exportadores de café en el mundo. Por esta razón, contar con información sobre las exportaciones de café para realizar predicciones puede resultar de utilidad, especialmente para el gremio de caficultores de Colombia (Federación Nacional de Cafeteros). Los datos fueron obtenidos de esta organización Federación Nacional de Cafeteros de Colombia, 2025.

Para este estudio se usarán dos series temporales de exportaciones: el total anual del volumen de exportación de café (medido en miles de sacos) y el valor de las exportaciones mensuales (medido en millones de dólares).

Los datos recopilados contienen información desde 1958 hasta 2024 para el caso del volumen anual y desde enero de 1958 hasta diciembre de 2024 para la variable del valor mensual.

Los gráficos de estas dos series temporales son los siguientes:




Figura 1: Gráficas de volumen y valor de exportaciones

Como se observa en la gráfica 1, existe una tendencia estocástica en ambos casos. Se nota la presencia de datos atípicos en la serie de volumen de exportación, lo cual puede inducir una volatilidad variable. En el valor de las exportaciones, se identifican distintos clústeres de volatilidad, especialmente a inicios de la década de los 80 y principios de los 90.

Con lo anterior se presentan los graficos de las funciones de autocorrelación y autocorrelación parcial de ambas series.

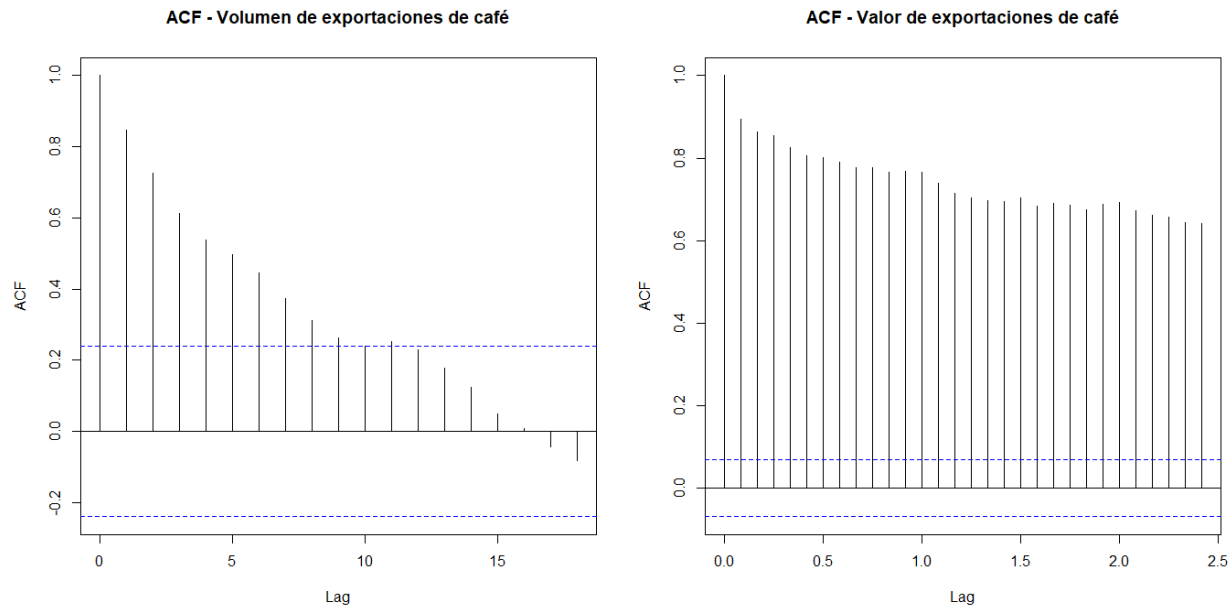


Figura 2: ACF Volumen y Valor

A juzgar por el gráfico 2 presentamos dos series no estacionarias para verificar esto les aplicaremos el test de Dickey-Fuller a ambas series, donde nuestra hipótesis nula es que nuestras series no son estacionarias vs la alterna que si sean estacionarias, al aplicarle este test a la serie de volumen tenemos un valor p de 0,52 por lo que no rechazamos la hipótesis de no estacionalidad, por otro lado para la serie valor el valor p es de 0,08425 por lo que tampoco rechazamos la hipótesis de estacionariedad con una confianza de 0,05, así pues realizaremos dos transformaciones a nuestros datos primero la función logaritmo natural para tratar de corregir los problemas de volatilidad que tenemos, y también la primera diferencia regular para con esto tratar de conseguir la estacionariedad, esto nos da como resultado la gráfica 3:

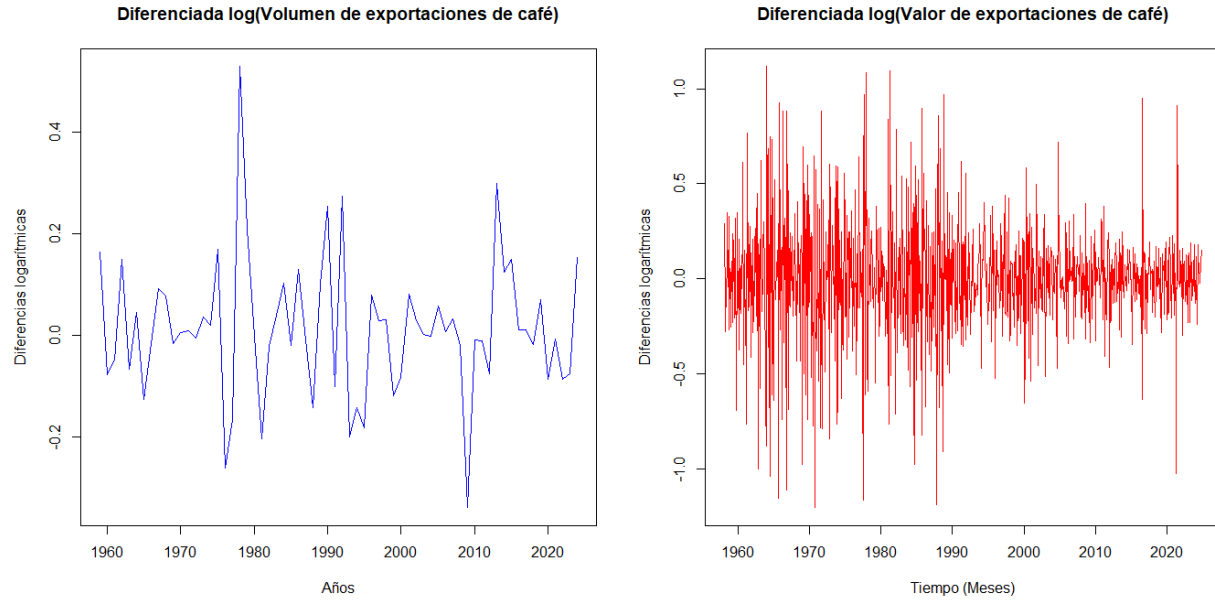


Figura 3: Gráfico de las series transformadas

Como vemos en esta gráfica 3 es mucho más estable al rededor de un valor medio y la volatilidad se ve sumamente disminuida, para comprobar esto vamos a volver a usar en estas dos series transformadas la prueba Dickey-Fuller dando los siguientes resultados, en este caso ambas series tuvieron un valor p en la prueba de 0,01 por lo que rechazamos la hipótesis de no estacionariedad por la hipótesis alterna por lo que estamos ante dos series que son estacionarias y con las que podremos trabajar los modelos que se presentaran en la siguiente sección, por otra parte para estas series transformadas vemos los graficos ACF y PACF en la gráfica 4:

Para efectos prácticos en el caso de la serie valores de exportación de café al diferenciar el logaritmo de la serie estamos trabajando con una aproximación a la serie de retorno, tal cual como se define en el libro de Shumway y Stoffer, 2017:

$$r_t \approx \nabla \log(x_t) = \log(x_t) - \log(x_{t-1}) = \log\left(\frac{x_t}{x_{t-1}}\right)$$

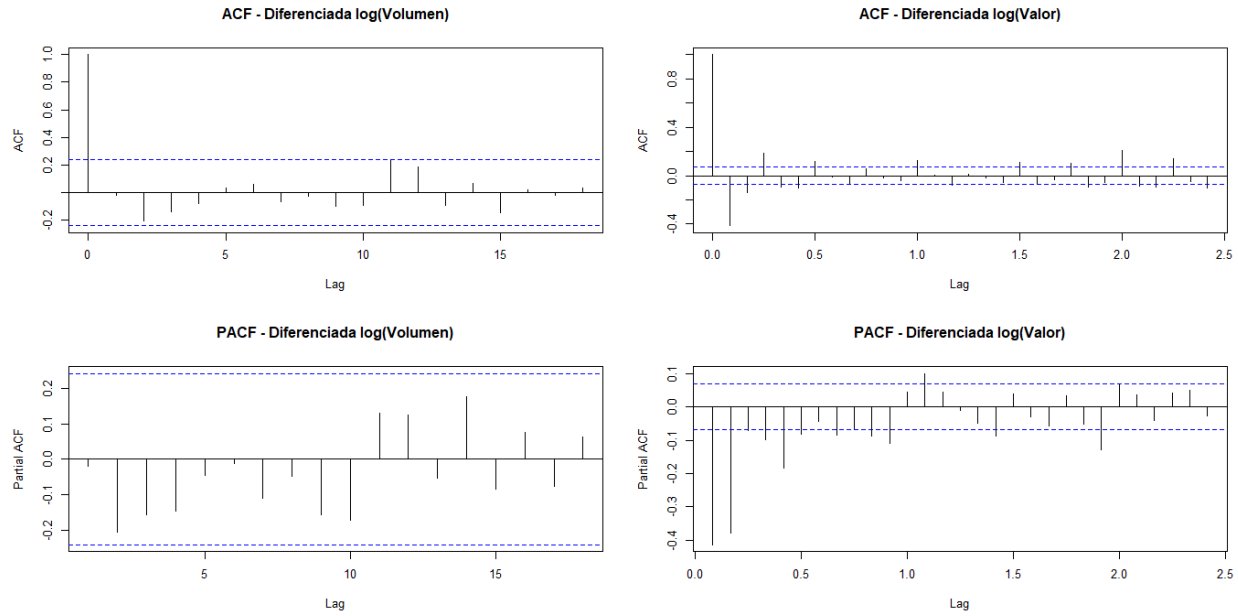


Figura 4: ACF y PACF series transformadas

En el gráfico 4 tenemos un comportamiento interesante tanto en la ACF como en la PACF de la variable volumen transformada donde no presenta resagos significativos en ninguna de las dos funciones, por otro lado para la serie valor transformada tanto su función ACF como PACF resultan decreciendo de forma sinusoidal.

2. Modelos propuestos: Serie Volumen

2.1. Análisis del Modelo ARIMA para el Volumen de Café Exportado en Colombia

La serie de tiempo bajo estudio comprende el volumen de café exportado en Colombia desde 1958 hasta 2024, con observaciones anuales. En un primer análisis visual se evidencia que la serie no presenta una tendencia determinista clara; en cambio, se observa una tendencia estocástica y no es claro si la serie presenta problemas de heterocedasticidad o patrones estacionales.

Para evaluar la capacidad predictiva de los modelos que vamos a ajustar esta serie de tiempo dividimos los datos desde 1958 hasta el 2021 como datos de entrenamiento y desde el 2022 hasta 2024 como datos de testeo.

Para evaluar si la serie presenta problemas de heterocedasticidad usamos los métodos de Guerrero y loglik para seleccionar un λ óptimo para la transformación de Box Cox. De ambos métodos se obtiene un λ cercano a cero por lo que procedemos a aplicar logaritmo natural a la serie. En la figura 5 se presenta la gráfica de la serie transformada.




Figura 5: logaritmo natural de la serie del volumen de café anual

Como podemos observar en la 5 parece que se logra una leve reducción de la variabilidad de la serie, esto se refuerza ya al aplicar el metodo loglik, nuevamente, para encontrar un λ optimo; obtuvimos un $\lambda = 0,8$ Como este valor es cercano a 1 podemos concluir que si se logro una reducccón de la variabilidad de la serie.

La función de autocorrelación (ACF) decae lentamente y muestra rezagos significativos hasta el rezago 12. Por otro lado, la función de autocorrelación parcial (PACF) destaca únicamente el primer rezago como significativo, lo que es característico de procesos autorregresivos de orden uno en el contexto de series estacionarias. Sin embargo, el comportamiento global sugiere la necesidad de transformaciones para alcanzar la estacionariedad.

Para evaluar la estacionariedad de la serie, se aplicaron dos pruebas fundamentales:

- **Prueba de Dickey-Fuller Aumentada (ADF):** Evalúa la presencia de una raíz unitaria en la serie de tiempo. Su sistema de hipótesis es:
 - H_0 : La serie tiene una raíz unitaria (no es estacionaria).
 - H_1 : La serie es estacionaria.

En este caso, el p-valor obtenido fue de 0.49, lo que impide rechazar la hipótesis nula y sugiere que la serie no es estacionaria.

- **Prueba KPSS (Kwiatkowski-Phillips-Schmidt-Shin):** Evalúa la hipótesis opuesta a la ADF, es decir:
 - H_0 : La serie es estacionaria.
 - H_1 : La serie no es estacionaria.

En este caso, el p-valor obtenido fue 0.01, lo que lleva a rechazar la hipótesis nula y confirmar que la serie no es estacionaria.

Dado que ambas pruebas concuerdan en la no estacionariedad, se procede a aplicar las transformaciones necesarias, considerando el logaritmo y una primera diferenciación, debido a las grandes fluctuaciones que tiene la serie.




Figura 6: Primera diferencia ordinaria para el logaritmo de la serie de volumen exportado de café.

La serie diferenciada presenta un comportamiento alrededor de cero, indicando que la tendencia ha sido eliminada. Las pruebas de estacionariedad sobre la serie transformada arrojaron los siguientes resultados:

- La prueba de Dickey-Fuller Aumentada ahora tiene un p-valor de 0.01, lo que sugiere que la serie diferenciada es estacionaria.
- La prueba KPSS mantiene un p-valor mayor a 0.1, lo que sugiere que la diferenciación eliminó el componente no estacionario.

También se observan sus autocorrelogramas:




Figura 7: ACF y PACF para el logaritmo del volumen exportado diferenciado.

El análisis del ACF y PACF del logaritmo de la serie diferenciada muestra la ausencia de rezagos significativos (salvo el lag 0, que siempre es 1), lo que es consistente con un proceso de ruido blanco.

Haciendo uso de la función `.auto.arima().evaluamos` el mejor modelo a ajustar con esta transformación, y con base en los análisis anteriores se ajustó un modelo $ARIMA(0,1,0)$, que corresponde a una caminata aleatoria. La expresión general del modelo es:

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2) \quad (1)$$

Con $Y_t = \ln(X_t)$.

El ajuste del modelo arrojó los siguientes valores:

- Log-verosimilitud: 35.59
- AIC: -69.19
- AICc: -69.12
- BIC: -67.04

El modelo $ARIMA(0,1,0)$ sugiere que el logaritmo del volumen de café exportado sigue un proceso de caminata aleatoria, donde los datos estacionarios no presentan componente autorregresivo ni de media móvil.

Al realizar el análisis de los residuos se observa lo siguiente:

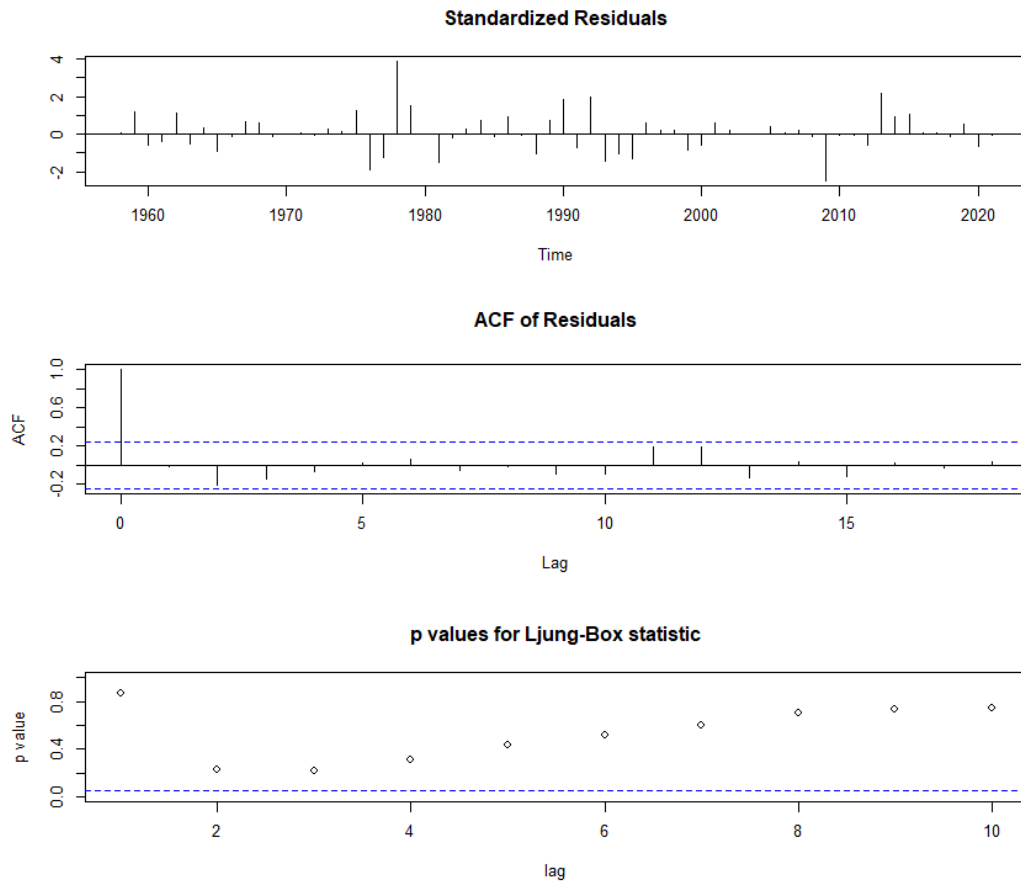


Figura 8: Análisis de residuales para el modelo ARIMA.

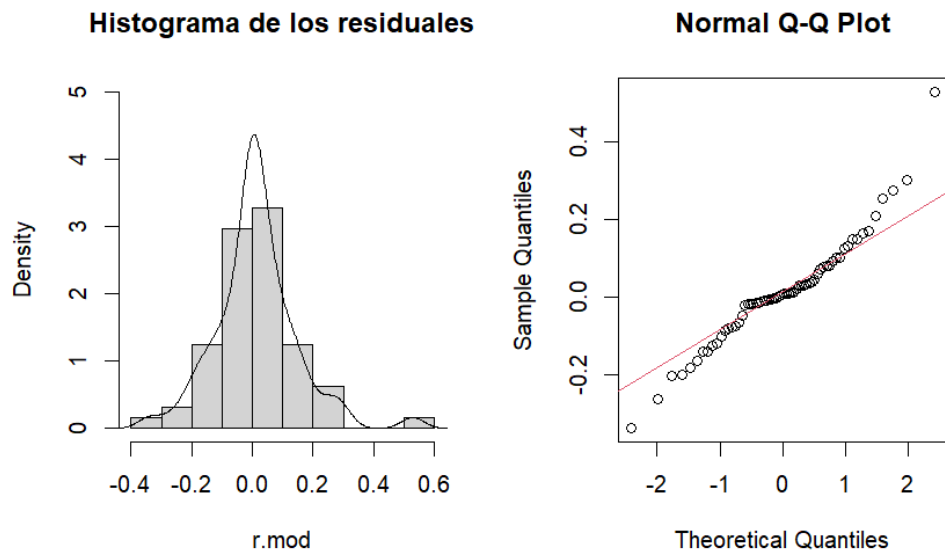


Figura 9: Histograma y Q-Q plot de los residuales para el modelo ARIMA.

- La prueba de Ljung-Box para los residuos del modelo ajustado arrojan p-valores mayores al umbral, lo que indica que no hay autocorrelación significativa en los residuos, lo que es un buen indicio de un modelo bien ajustado.
- El histograma de los residuos se asemeja a una distribución normal, aunque la prueba de Shapiro-Wilk da un p-valor de 0.009815, lo que sugiere que los residuos presentan alguna desviación de la normalidad.
- Tanto el gráfico de la Figura 8 como el Q-Q plot de la Figura 9 parecen indicar que hay presencia de datos atípicos.

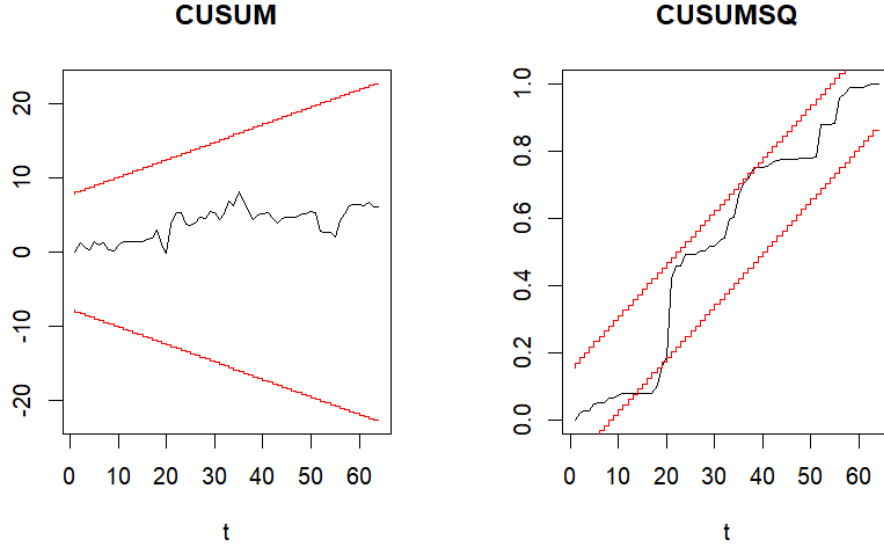


Figura 10: Cartas CUSUM y CUSUMQ de los residuales para el modelo ARIMA.

Como podemos ver en las cartas CUSUM y CUSUMQ de la Figura 10 indican que el modelo está bien especificado y no parece tener muchos problemas de heterocedasticidad.

Realizando un análisis de datos atípicos identificamos los siguientes datos atípicos:

Type	Ind	Coefhat	T-stat
AO	20	-0.3475413	-4.587005
LS	21	0.5286932	4.934141

Cuadro 1: Resultados de detección de valores atípicos

Como podemos ver en la Tabla 1 en el año 1978 ocurre un cambio abrupto en el volumen de café y en el año 1979 ocurre un cambio de nivel permanente en la serie de tiempo. Modelando estos datos atípicos a través de intervenciones obtenemos el siguiente modelo:

$$Y_t = Y_{t-1} + w_0 I_t^{(20)} + w_1 S_t^{(21)} + \varepsilon_t, \quad \varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2) \quad (2)$$

Con $Y_t = \ln(X_t)$.

Estimando el modelo con intervenciones obtenemos los siguientes valores:

	AO20	LS21
Coefficients	-0.1664	0.3623
s.e. (Error estándar)	0.1185	0.1676

Cuadro 2: Estimaciones de coeficientes y errores estándar para los valores atípicos

- Log-verosimilitud: 44.99
- AIC: -83.97
- AICc: -83.56
- BIC: -77.54

Como podemos observar en la tabla 2 ambos coeficientes son significativos lo que indica que si existen dichos datos atípicos. Además, la estimación de este modelo mejora los criterios de bondad de ajuste pues son menores a los del modelo sin intervenciones.

Analizando los residuales del modelo obtenemos lo siguiente:

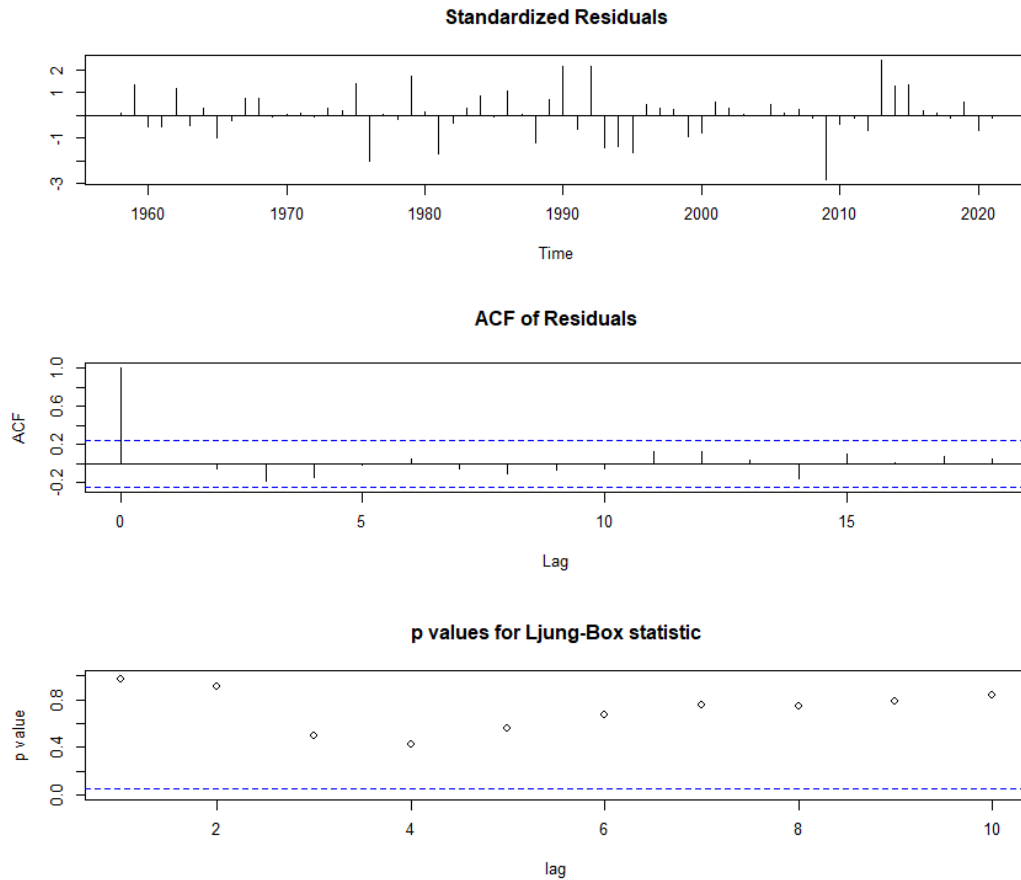


Figura 11: Análisis de residuales para el modelo ARIMA con intervenciones.




Figura 12: Histograma y Q-Q plot de los residuales para el modelo ARIMA con intervenciones.

Como podemos ver en la Figura 11 los residuales estandarizados parecen estar entre -3 y 3 lo cual indica que no hay más valores atípicos; en el autocorrelograma de los residuos no hay rezagos significativamente distintos de cero lo que indican que son un ruido blanco y la prueba de Ljung-Box para los residuos del modelo ajustado arrojan p-valores mayores al umbral, lo que indica que no hay autocorrelación significativa en los residuos, lo que es un buen indicio de un modelo bien ajustado.

Los gráficos de la Figura 12 parecen indicar que puede que halla normalidad en los datos pues aunque las colas pesadas en el Q-Q plot el test de Shapiro-Wilk indica que NO se rechaza H_0 con un valor-p de 0,1009 en favor de que la distribución es normal.




Figura 13: Cartas CUSUM y CUSUMQ de los residuales para el modelo ARIMA con intervenciones.

En cuanto a las cartas CUSUM y CUSUMQ de la Figura 13 podemos observar que el modelo esta bien especificado y que se no hay grandes problemas de heterocedasticidad.

Analizando la habilidad predictiva del modelo con y sin intervenciones obtendremos los siguientes resultados:

Modelo	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Sin Intervenciones	340.4915	1116.11	892.5975	2.416913	7.63565	0.6941638	-0.4029575
Con Intervenciones	339.1264	1115.983	891.2324	2.404946	7.623684	0.6931022	-0.4017877

Cuadro 3: Métricas de capacidad predictiva entre el modelo sin intervenciones y con intervenciones

Como podemos observar en la Tabla 3 las medidas de calidad de predicción entre ambos modelos son muy parecidas aunque las del modelo con intervenciones es ligeramente mejor tanto en bondad de ajuste como en medidas de predicción.

Se realizó un ejercicio de pronóstico a 5 años, aunque dados los resultados no se espera un resultado interesante.




Figura 14: Pronósticos e intervalos de confianza para los próximos 5 años.

Se indica que la media se mantiene constante en aproximadamente 12,322.86 unidades exportadas, con intervalos de confianza simétricos en torno a este valor. El amplio rango de los intervalos de confianza refleja la incertidumbre inherente a un modelo de caminata aleatoria.

Los resultados de la aplicación de este modelo sugieren que el volumen de café exportado en Colombia sigue un proceso de caminata aleatoria, lo que implica que las exportaciones futuras son altamente inciertas y dependen en gran medida de factores externos. La ausencia de una estructura autorregresiva o de media móvil refuerza la hipótesis de que el proceso es puramente estocástico, sin una dinámica predictiva más allá de la media histórica.

3. Modelos propuestos: Serie de valores

3.1. Análisis de Descomposición de la Serie

La gráfica original de la serie muestra épocas con cambios bruscos en la volatilidad, lo que sugiere la presencia de heterocedasticidad en los datos. Para mitigar este efecto, se aplicó la transformación de Box-Cox, obteniéndose un parámetro λ óptimo de 0.1786157. Al aplicar esta transformación se observó una mejora en la estabilidad de la varianza. Dado que dicho valor de λ es relativamente cercano a cero, también se evaluó la transformación logarítmica, la cual arrojó resultados similares, sugiriendo que ambas estrategias logran reducir, aunque no eliminar completamente, la heterocedasticidad.




Figura 15: Comparación entre las transformaciones de la serie.

Antes de exponer los resultados de las descomposiciones propiamente dichas, se procedió a analizar los residuos de los modelos para determinar qué modelo resulta más adecuado para el pronóstico, evitando así el análisis excesivo de alternativas no competitivas.

En el caso de la **descomposición aditiva**, se observaron que los residuos de la serie original, así como de las series transformadas mediante Box-Cox y logarítmica, presentan un comportamiento heterocedástico persistente. Es decir, la varianza de los errores no se estabiliza y varía de manera significativa a lo largo del tiempo. Esto indica que, pese a la aplicación de transformaciones, el modelo aditivo no logra capturar de forma adecuada la dinámica de la volatilidad de la serie.

Por otro lado, en la **descomposición multiplicativa** se observa que aunque los residuos presentan heterocedasticidad, ello es esperado en un modelo multiplicativo, ya que este tipo de modelo asume que los componentes (tendencia, estacionalidad y residuos) se relacionan de manera proporcional. Los residuos se distribuyen alrededor de 1 (en lugar de 0, como en el aditivo), y su comportamiento es coherente con la naturaleza multiplicativa del modelo.

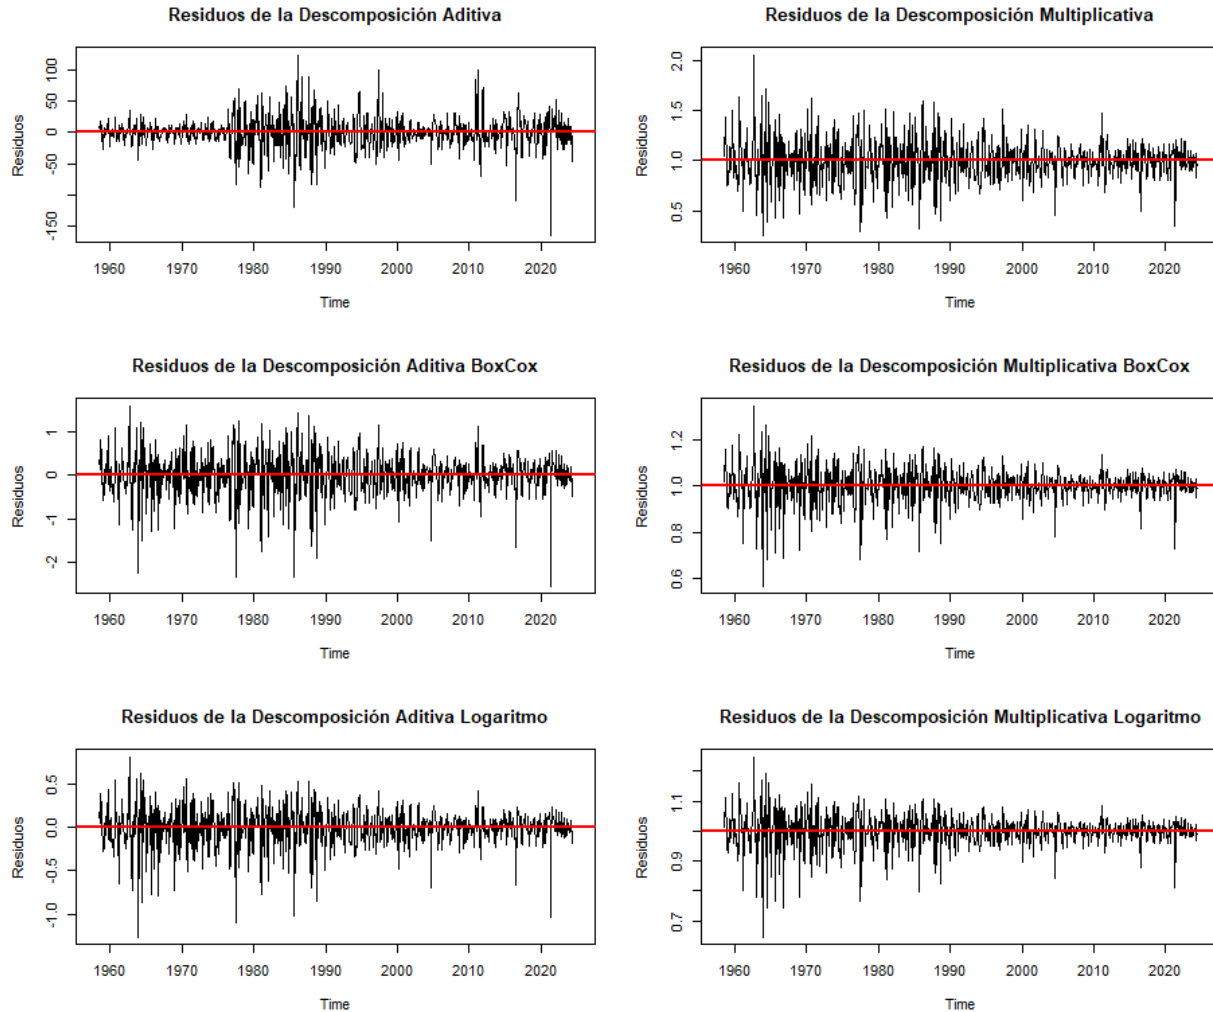


Figura 16: Residuos de los modelos aditivo y multiplicativo en la serie original, con transformada Box-Cox y logarítmica.

Conclusión: El modelo multiplicativo logra capturar de manera adecuada la estructura de la serie, incluyendo la variabilidad proporcional, por lo que se opta por este modelo para la etapa de pronóstico.

Al aplicar la descomposición multiplicativa se obtuvieron los siguientes resultados:

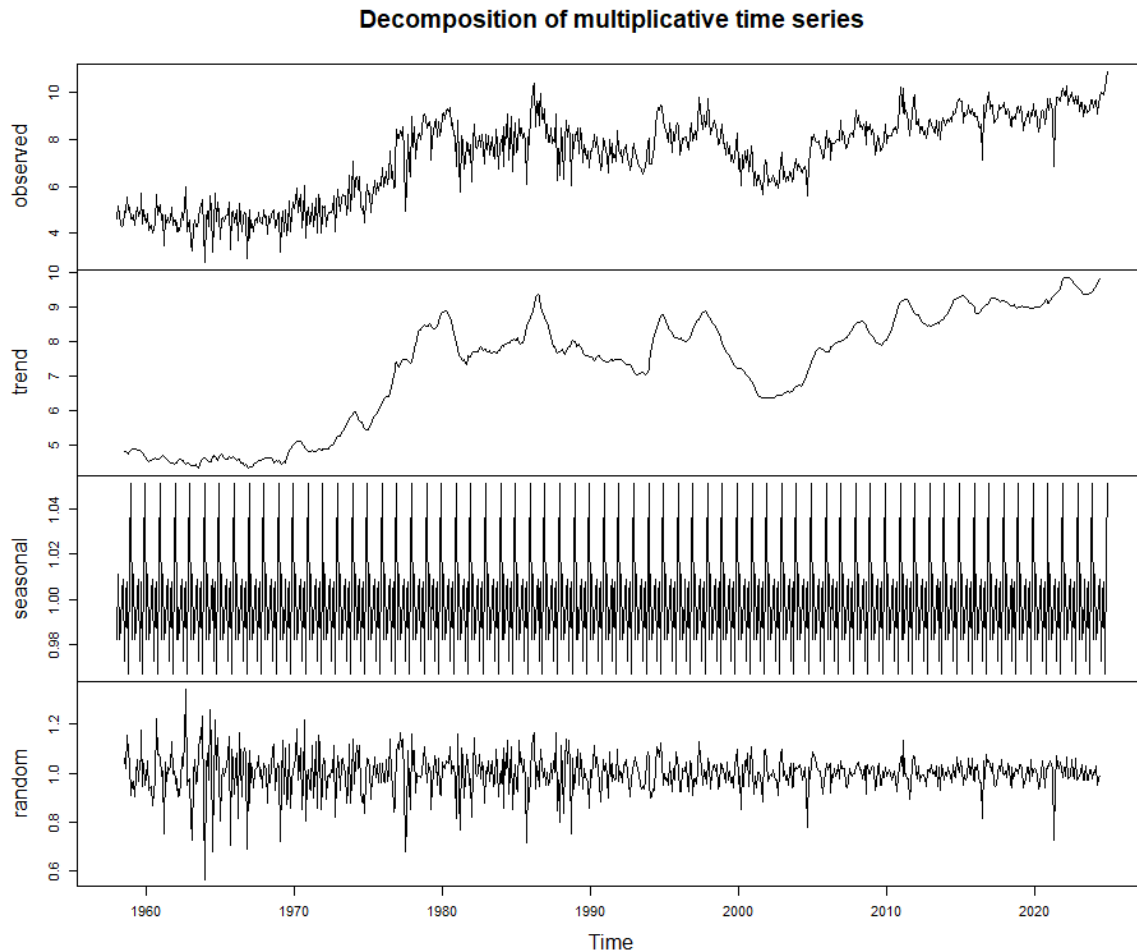


Figura 17: Descomposición multiplicativa de la serie transformada.

- Aunque los residuos presentan heterocedasticidad, ello es esperado en un modelo multiplicativo, ya que se asume que los componentes (tendencia, estacionalidad y residuos) se relacionan de manera proporcional.
- Los residuos se distribuyen en torno a 1 (en lugar de 0, como ocurre en la descomposición aditiva), lo cual es coherente con la naturaleza multiplicativa del modelo.

El modelo multiplicativo captura de forma adecuada la estructura de la serie, especialmente en lo que respecta a la estacionalidad y la variabilidad proporcional.

Se aplicó el test de Dickey–Fuller a cada uno de los componentes obtenidos en la descomposición multiplicativa de la serie transformada:

Tendencia: $p\text{-valor} = 0,2811$,
Estacionalidad: $p\text{-valor} = 0,01$,
Residuos: $p\text{-valor} = 0,01$.

Estos resultados indican que, de los tres componentes, únicamente la tendencia presenta no estacionariedad, lo cual es coherente con la interpretación de la tendencia como la parte evolutiva a largo plazo de la serie.

Se realizaron pruebas adicionales para evaluar la distribución e independencia de los residuos:

- **Shapiro–Wilk:** Se obtuvo $W = 0,94245$ con $p\text{-valor} < 2,2 \times 10^{-16}$, lo que evidencia una fuerte desviación de la normalidad.
- **Box–Ljung:** Con $X^2 = 1,232$ ($df = 1$) y $p\text{-valor} = 0,267$ no se evidencia autocorrelación significativa.

El modelo multiplicativo aplicado sobre la serie transformada con Box-Cox permite separar de forma coherente la estacionalidad y los residuos, los cuales resultan estacionarios, mientras que la tendencia se mantiene no estacionaria, reflejando la evolución a largo plazo de la serie. Aunque los residuos no siguen una distribución normal, la ausencia de autocorrelación significativa respalda la idoneidad del modelo para fines predictivos. En definitiva, se opta por el modelo multiplicativo, ya que captura de manera robusta los patrones estacionales y la dinámica proporcional inherente a la serie.

3.1.1. Modelos SARIMA

El primer tipo de modelos que consideraremos son los modelos $\text{SARIMA}(p,d,q)\times(P,D,Q)[12]$, Después de escoger secuencialmente por AIC, obtuvimos que para el logaritmo de la serie de valores el mejor modelo es: $\text{SARIMA}(2,1,3)\times(0,0,2)[12]$, lo cual es equivalente a un modelo $\text{SARIMA}(2,0,3)\times(0,0,2)[12]$ para la serie de retornos:

Sea $R_t := \nabla \log(X_t)$; la serie de retornos.

$$R_t = \phi_1 R_{t-1} + \phi_2 R_{t-2} + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \Theta_1 Z_{t-12} + \Theta_2 Z_{t-24}$$

con $\{Z_t\} \sim WN(0, \sigma^2)$.

3.1.2. Validación




Figura 18: Validación sarima

Como podemos ver en la figura 18 los residuos a partir del rezago 4 no pasan la prueba de Ljung-Box, es decir no son ruido blanco y los residuos estandarizados conservan los patrones de volatilidad que el modelo no pudo capturar.

Esto lo podemos verificar con las cartas cusum y cusumq:




Figura 19: Cartas de cusum de modelo Sarima

Como vemos en la figura 19 evidentemente aunque parece no haber cambios estructurales, el modelo tiene presencia de heterocedasticidad que el supuesto de varianza constante de los Ruidos Blancos, no es apropiado.

A continuación vamos a ver el ACF y PACF de los residuales al cuadrado para ver si tenemos presencia de efectos Arch.

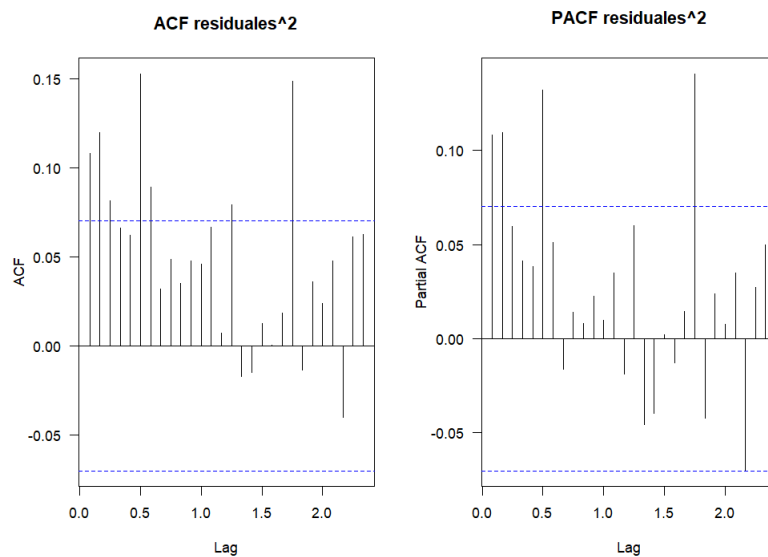


Figura 20: Residuales al cuadrado

Como vemos en la figura 20, vemos presencia de efectos arch que confirmamos con la prueba ARCH LM-test del paquete `FinTS` de R, para dos rezagos el pv valor es 0.000102 menor a una significancia del 5% por lo que hay presencia de efectos Arch, es decir: hay un problema de heterocedasticidad que es **autoregresivo y condicional**.

3.1.3. Pronosticos




Figura 21: Pronosticos en serie de retornos




Figura 22: Pronosticos retornos a futuro

Figura 23: Pronosticos combinados

Como podemos ver los pronósticos de la serie de retornos tienden a la media al igual que los pronósticos de la serie de valor real y los intervalos de confianza son bastante amplios por lo menos en la serie de valor real.

3.1.4. Modelos Arma-Garch

Dado que ambas series parecen presentar problemas de volatilidad, En esta sección consideramos, varios tipos de modelos, incluidos los Standar Grach ó **SGarch** con diferntes modelos arma para la media. GARCH(p,q) (Generalized Autoregressive Conditional Heteroskedasticity), que se define como:

$$X_t = \sqrt{\sigma_t^2} e_t$$

donde

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i Z_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

con $\alpha_0 > 0$, $\alpha_j, \beta_j \geq 0$ y $\{e_t\} \sim IID(0, 1)$.

También incluimos el modelo de Glosten-Jagannathan-Runkle o **GJR-GARCH** que Modela los choques positivos y negativos en la varianza condicional de manera asimétrica mediante el uso de la función indicadora I .

$$\sigma_t^2 = \alpha_0 + \sum_{j=1}^q (\alpha_j \varepsilon_{t-j}^2 + \gamma_j I_{t-j} \varepsilon_{t-j}^2) + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Donde γ_j ahora representa el término de apalancamiento. La función indicadora I toma el valor de 1 para $\varepsilon \leq 0$ y 0 en caso contrario. Debido a la presencia de la función indicadora, la persistencia del modelo ahora depende crucialmente de la asimetría de la distribución condicional utilizada. La persistencia del modelo \hat{P} .

$$\hat{P} = \sum_{j=1}^q \alpha_j + \sum_{j=1}^p \beta_j + \sum_{j=1}^q \gamma_j \kappa$$

donde κ es el valor esperado de los residuos estandarizados z_t por debajo de cero (efectivamente, la probabilidad de estar por debajo de cero). Es decir:

$$\kappa = E[Z_{t-j}I_{t-j}]$$

Ajustando los distintos modelos con la misma especificación para la parte arma del modelo siendo la definida en la parte anterior siendo el orden **Arma(2,3)**.

Haciendo una inicial revisión de los residuales ajustados nos dimos cuenta de la presencia de colas pesadas, por lo que vamos a cambiar las distintas opciones de densidad condicional para las innovaciones. “ged” para the generalized error distribution, “std” para t-student y “sst” para la the skew-student.

Vamos a escoger el modelo en terminos del AIC:

arma-sgarch(2,3)(1,2), arma-sgarch(2,3)(1,1), arma-sGarch-std(2,3)(1,1), arma-sGarch-sstd(2,3)(1,1), arma-sGarch-ged(2,3)(1,1), arma-gjrGarch-ged(2,3)(1,1), arma-sGarch-std(2,3)(2,1), arma-gjrGarch-sstd(2,3)(1,1).

	1	2	3	4	5	6	7	8
AIC	0.1649	0.1642	0.0492	0.0264	0.0546	0.0563	0.0518	0.0419
BIC	0.2127	0.206	0.1089	0.0921	0.1143	0.1219	0.1174	0.1135
Shibata	0.1647	0.1641	0.0489	0.026	0.0543	0.0559	0.0514	0.0414
Hannan-Quinn	0.1833	0.1803	0.0722	0.0517	0.0776	0.0815	0.077	0.0694

Cuadro 4: Tabla de AIC, BIC, Shibata y Hannan-Quinn

El modelo escogido entonces es 4: ARMA-sGarch-sstd(2,3)(1,1):

3.1.5. Validacion modelo Arma-Garch




Figura 24: ACF RES




Figura 25: ACF RES2




Figura 26: QQplot sstd




Figura 27: Desv.std Condicional

3.1.6. Pronosticos

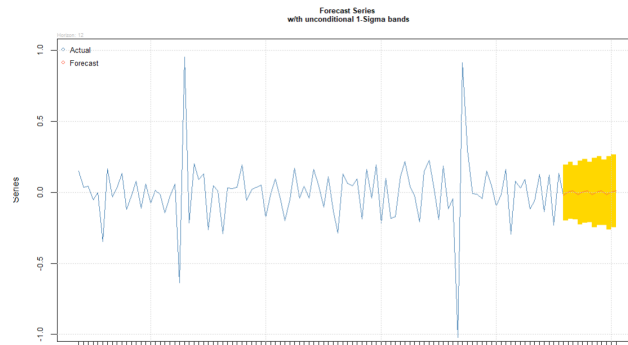


Figura 28: Pronosticos serie Garch

Como podemos ver en el gráfico anterior28 tenemos que el modelo tiende a pronosticar el valor medio.

Vamos a ver que ajustando el modelo arma-garch seleccionado para todo el conjunto de datos y pronosticando la serie para los proximos 6 meses tenemos que:




Figura 29: Pronosticos serie Garch 6 meses a futuro

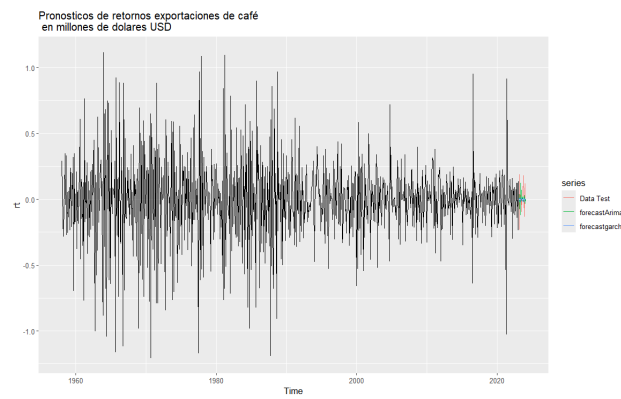


Figura 30: Pronosticos a futuro en comparación modelo Sarima y Arma-Garch seleccionado

Como vemos en la figura 30, los pronosticos quien mejor parece paturar la variabilidad es el Garch.

3.2. Modelo Alternativo para la Variable Valores

Para construir un modelo comparable al modelo GARCH, utilizaremos nuevamente los retornos de la variable.

El modelo presentado a continuación es una red neuronal que combina el uso de una red neuronal convolucional con redes LSTM, como se muestra en el gráfico del modelo 31.

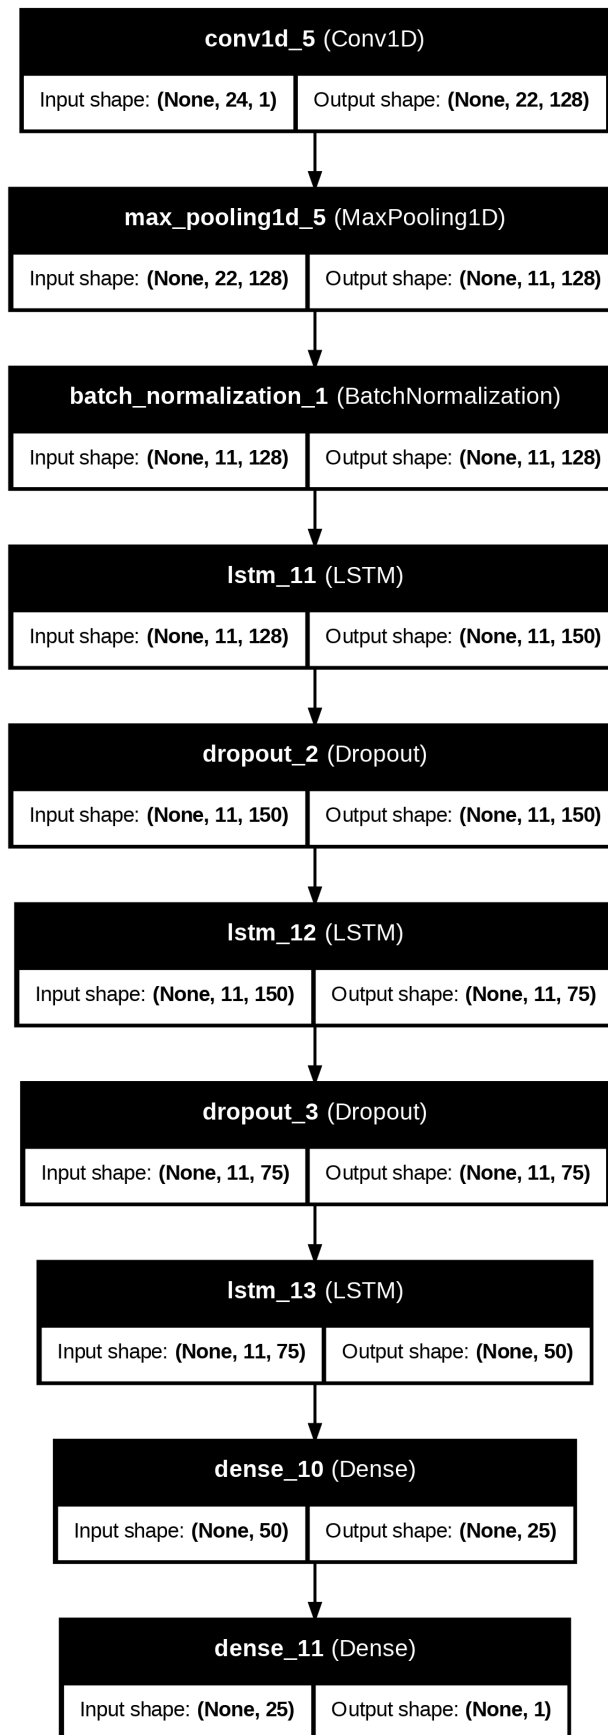


Figura 31: Modelo Red Neuronal

Esta arquitectura ha sido seleccionada porque la capa convolucional permite extraer patrones locales en los datos, mientras que las capas LSTM capturan comportamientos a largo plazo en la serie temporal. Para el entrenamiento, los datos fueron organizados de manera secuencial, generando ventanas de 24 datos previos al valor que se busca predecir. Estos datos son luego ingresados al modelo para su entrenamiento.

De manera similar al modelo GARCH, se utilizarán los últimos 12 meses de la variable para comparar las predicciones de ambos modelos. Esta comparación es relevante, ya que, a diferencia del modelo GARCH, este modelo no se basa en supuestos distribucionales, lo que impide una comparación directa con las medias comúnmente utilizadas.

Tras el entrenamiento, la función de pérdida alcanzó un valor de $loss = 0,0030$, como se muestra en el gráfico 32. Posteriormente, al evaluar el modelo con los últimos 12 meses de la serie, los cuales no fueron utilizados en el entrenamiento, se obtuvo un RMSE de 0,1394334. Los valores predichos pueden observarse en la gráfica 33, donde se comparan los 12 valores reales con los 12 valores predichos. Además, en la gráfica 34 se presentan estos valores en el contexto de la serie completa.




Figura 32: Pérdida durante el entrenamiento del modelo




Figura 33: Validación de los últimos 12 valores




Figura 34: Validación completa de los últimos 12 valores

Con estos resultados, el modelo fue reentrenado utilizando los mismos parámetros previamente obtenidos como valores de arranque, pero ahora incluyendo la muestra total. Con esta muestra completa, se realizaron predicciones para los siguientes 6 periodos futuros. Estas predicciones se presentan junto con los últimos 24 valores observados de la variable en la gráfica 35, mientras que la gráfica 36 muestra los datos completos y las 6 predicciones.




Figura 35: Predicciones para los próximos 6 periodos




Figura 36: Predicciones completas para los próximos 6 periodos

En conclusión, este modelo demuestra ser razonablemente efectivo, considerando la complejidad de la serie temporal analizada. No obstante, al compararlo con el modelo GARCH, se observa que este último, al ser paramétrico, ofrece ventajas considerables, como la posibilidad de realizar inferencias sobre las predicciones mediante intervalos de confianza.

3.3. Comparación mejor modelo

Modelo	RMSE
ARMA-GARCH	0.1386556
Red Neuronal	0.1394334

Cuadro 5: Comparación de RMSE entre modelos

Referencias

- Federación Nacional de Cafeteros de Colombia. (2025). Coffee Statistics [Último acceso: 4 de febrero de 2025].
<https://federaciondecafeteros.org/wp/coffee-statistics/?lang=en>
- Shumway, R. H., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications: With R Examples* (4th). Springer.