

# Análisis de Series Temporales de Exportaciones de Café

Jhon Alejandro Ramírez Daza, Javier Felipe Rodríguez Ardila, Juan Felipe Moreno Rodríguez, Brad Dereck Roza Rubio

08 de marzo- 2025



# Descripción de los datos

- Colombia es uno de los mayores exportadores de café.
- Se analizan dos series temporales: volumen anual de exportaciones y valor mensual de exportaciones.
- Datos obtenidos de la Federación Nacional de Cafeteros (1958-2024).




Figure: Volumen y valor de exportaciones

# Análisis de estacionariedad

- Se observa una tendencia estocástica y datos atípicos en el volumen.
- Prueba Dickey-Fuller:
  - Volumen:  $p\text{-valor} = 0.52$  (no estacionaria).
  - Valor:  $p\text{-valor} = 0.08425$  (no estacionaria a 5% de significancia).
- Se aplican transformaciones logarítmicas y diferenciación.

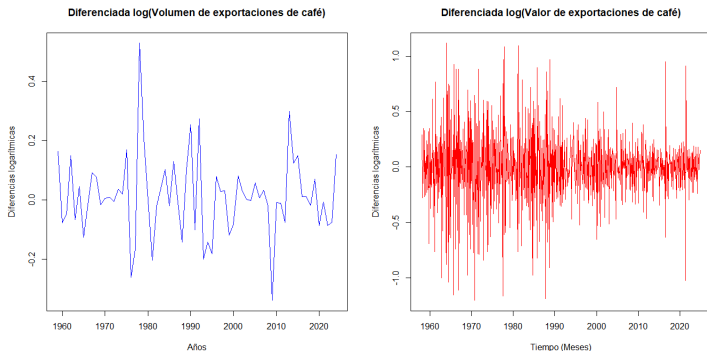


Figure: Series transformadas

# Análisis de estacionariedad

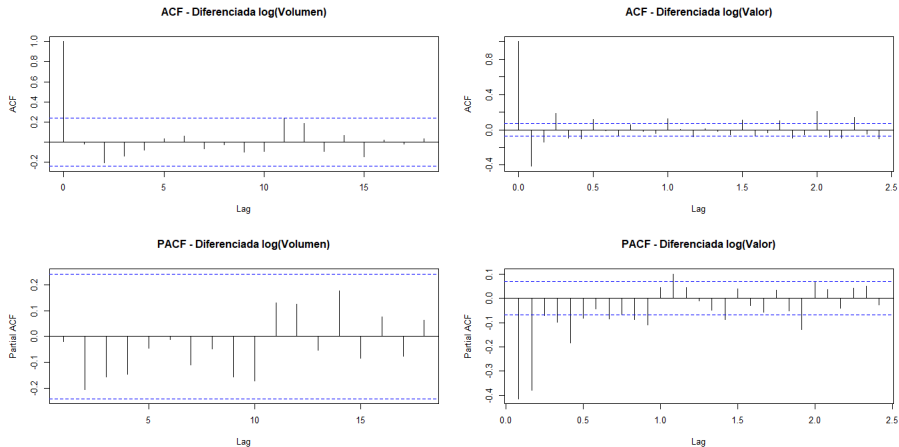



Figure: ACF y PACF series transformadas

# Modelo ARIMA para el Volumen

- Aplicación de transformaciones necesarias.
  - Logaritmo (BoxCox con un  $\lambda$  pequeño).
  - Primera diferencia regular.
- Se logra una reducción en la variabilidad la serie y un comportamiento estacionario.


**Diferencia regular del log de la serie (d=1)**




# Pruebas de estacionariedad

- Pruebas de estacionariedad.
  - La prueba de Dickey-Fuller Aumentada ahora tiene un p-valor de 0.01, lo que sugiere que la serie diferenciada es estacionaria.
  - La prueba KPSS mantiene un p-valor mayor a 0.1, lo que sugiere que la diferenciación eliminó el componente no estacionario.
- También se observan sus autocorrelogramas:

**ACF - Log Serie Diferenciada**



**PACF - Log Serie Diferenciada**



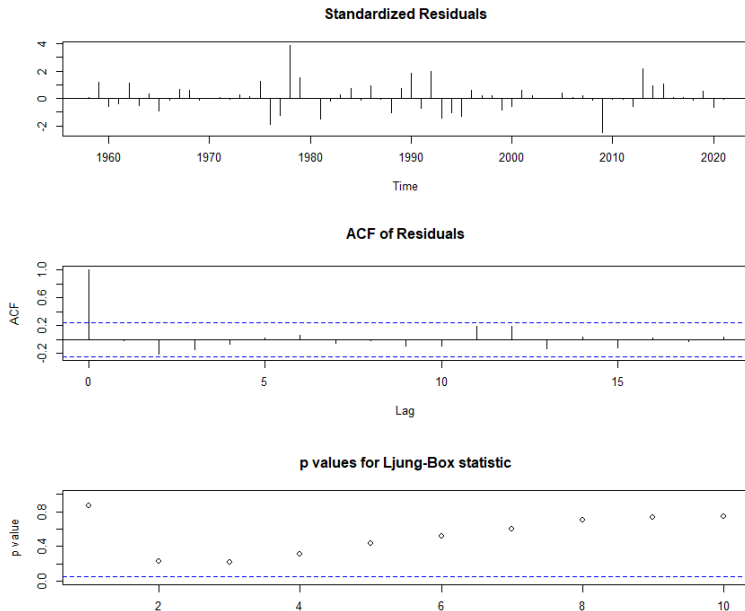
# Ajuste

- En la evaluación de los modelos aplicables se obtiene un buen ajuste de una camina aleatoria.
- ARIMA(0,1,0)
- La expresión general del modelo es:

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2) \quad (1)$$

- El ajuste del modelo arrojó los siguientes valores:
  - Log-verosimilitud: 35.59
  - AIC: -69.19
  - AICc: -69.12
  - BIC: -67.04

# Análisis de residuos





# Análisis de residuos

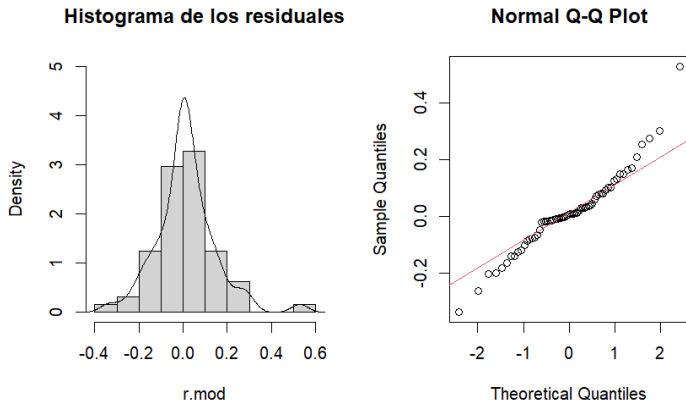


Figure: Histograma y Q-Q plot de los residuales para el modelo ARIMA.

# Análisis de residuos

- La prueba de Ljung-Box para los residuos del modelo ajustado arroja un p-valor mayor al umbral.
- El histograma de los residuos se asemeja a una distribución normal, aunque la prueba de Shapiro-Wilk da un p-valor de 0.009815.
- El gráfico de la Figura 6 y el Q-Q plot de la Figura 7 parecen indicar que hay presencia de datos atípicos.

# CUSUM y CUSUMQ




Figure: Cartas CUSUM y CUSUMQ de los residuales para el modelo ARIMA.

# Datos Atípicos

Type	Ind	Coefhat	T-stat
AO	20	-0.3475413	-4.587005
LS	21	0.5286932	4.934141

**Table:** Resultados de detección de valores atípicos

$$Y_t = Y_{t-1} + w_0 I_t^{(20)} + w_1 S_t^{(21)} + \varepsilon_t, \quad \varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2)$$

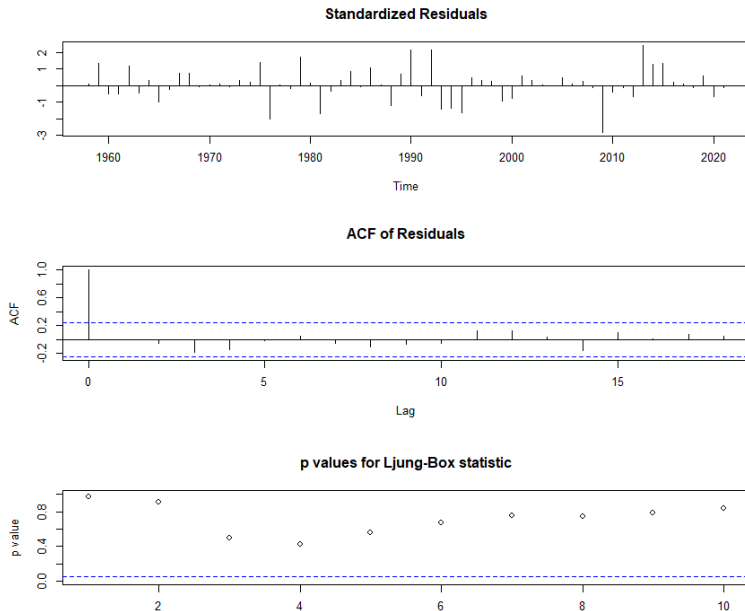
# Datos Atípicos: Medidas de Ajuste

	AO20	LS21
Coefficients	-0.1664	0.3623
s.e. (Error estándar)	0.1185	0.1676

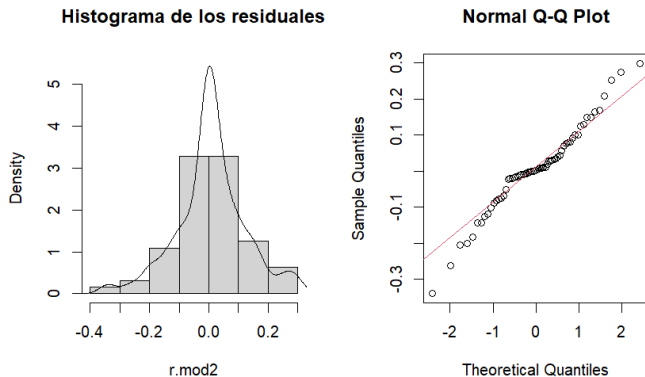
**Table:** Estimaciones de coeficientes y errores estándar para los valores atípicos

- Log-verosimilitud: 44.99
- AIC: -83.97
- AICc: -83.56
- BIC: -77.54

# Datos Atípicos: Análisis de Residuales




# Datos Atípicos: Análisis de Residuales



**Figure:** Histograma y Q-Q plot de los residuales para el modelo ARIMA con intervenciones.

- Shapiro-Wilk: valor- $p=0.1009$

# Datos Atípicos: Análisis de Residuales



**Figure:** Cartas CUSUM y CUSUMQ de los residuales para el modelo ARIMA con intervenciones.



# Medidas de Calidad de Predicción

Modelo	ME	RMSE	MAE	MPE
Sin Intervenciones	340.4915	1116.11	892.5975	2.416913
Con Intervenciones	339.1264	1115.983	891.2324	2.404946

**Table:** Métricas de capacidad predictiva entre el modelo sin intervenciones y con intervenciones

# Predicción del modelo ARIMA con intervenciones




Figure: Pronósticos e intervalos de confianza para los próximos 5 años.

# Análisis de Descomposición Valor del café

- Se comapran:
  - Sin transformación.
  - Transformación de BoxCox.
  - Logaritmo.




Figure: Comparación entre las transformaciones de la serie.

# Valoración de los residuales

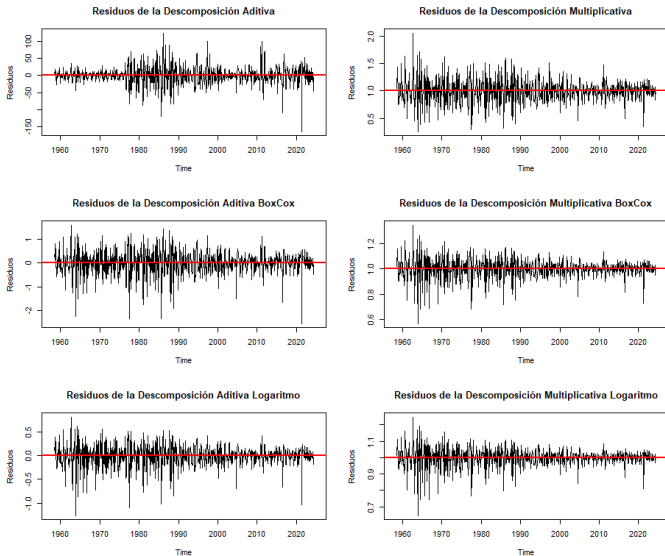



Figure: Residuos de los modelos aditivo y multiplicativo en la serie original, con

# Descomposición multiplicativa.



**Figure:** Descomposición multiplicativa de la serie transformada.

- Test de Dickey–Fuller a cada uno de los componentes obtenidos:

**Tendencia:**  $p\text{-valor} = 0.2811$ ,

**Estacionalidad:**  $p\text{-valor} = 0.01$ ,

**Residuos:**  $p\text{-valor} = 0.01$ .

- Pruebas adicionales para evaluar la distribución e independencia de los residuos:
  - **Shapiro–Wilk:** Se obtuvo  $W = 0.94245$  con  $p\text{-valor} < 2.2 \times 10^{-16}$ , lo que evidencia una fuerte desviación de la normalidad.
  - **Box–Ljung:** Con  $X^2 = 1.232$  ( $df = 1$ ) y  $p\text{-valor} = 0.267$  no se evidencia autocorrelación significativa.

# Modelos SARIMA

- Modelo SARIMA(2,0,3)×(0,0,2)[12] para la serie de retornos:  
Sea  $R_t := \nabla \log(X_t)$ ; la serie de retornos.

$$R_t = \phi_1 R_{t-1} + \phi_2 R_{t-2} + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \theta_3 Z_{t-3} \\ + \Theta_1 Z_{t-12} + \Theta_2 Z_{t-24}$$

con  $\{Z_t\} \sim WN(0, \sigma^2)$ .

## ● Validación con prueba de Ljung-Box.




Figure: Validación del modelo SARIMA



# Heterocedasticidad




Figure: Cusumu y cusumq sarima

# Detección de heterocedasticidad

- Presencia de efectos ARCH confirmados con prueba ARCH LM.
- Residuales muestran patrones de volatilidad.




Figure: Residuales al cuadrado

# Pronósticos en la Serie de Retornos




Figure: Pronósticos en serie de retornos




Figure: Pronósticos a futuro

Pronósticos

# Modelos Garch

- sGarch

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

con  $\alpha_0 > 0$ ,  $\alpha_j, \beta_j \geq 0$  y  $\{\epsilon_t\} \sim IID(0, 1)$ .

- GJR-GARCH

$$\sigma_t^2 = \alpha_0 + \sum_{j=1}^q (\alpha_j \epsilon_{t-j}^2 + \gamma_j I_{t-j} \epsilon_{t-j}^2) + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

# Modelos ARMA-GARCH

- Se prueba ARMA(2,3) con modelos GARCH y GJR-GARCH.
- Se comparan distribuciones de errores: GED, t-student, skew-student.
- Selección basada en AIC y BIC.

Modelo	AIC	BIC
SGARCH(1,2)	0.1649	0.2127
SGARCH-sstd(1,1)	0.0492	0.1089
GJR-GARCH-ged(1,1)	0.0563	0.1143

Table: Comparación de modelos GARCH

# Validación Arma-Garch

El modelo escogido entonces es 4: ARMA-sGarch-sstd(2,3)(1,1):




Figure: ACF RES

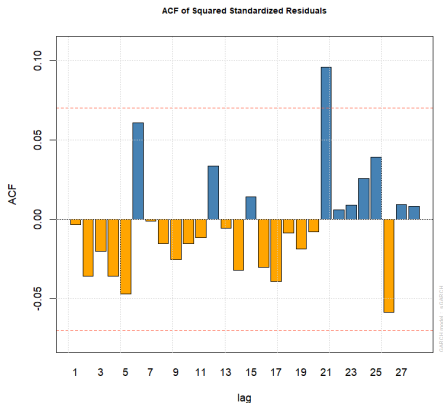


Figure: ACF RES2

# ValidacionII

sstd - QQ Plot




Figure: QQplot sstd

Conditional SD (vs |returns|)




Figure: Desv.std Condicional

# Pronosticos




Figure: Pronosticos intra muestra




Figure: Pronosticos a futuro 6 meses



# Red Neuronal para Series de Tiempo

- Uso de redes neuronales para modelar series temporales.
- Estructura de la red: capas, neuronas y funciones de activación.
- Implementación en Keras.

# Modelo Alternativo para la Variable Valores

- Uso de una red neuronal convolucional combinada con LSTM.
- Extracción de patrones locales y captura de dependencias a largo plazo.
- Entrenamiento con ventanas de 24 datos previos.

# Arquitectura del Modelo

Entrada



Conv1D



LSTM



Dropout



LSTM



# Evaluación del Modelo

- Pérdida durante el entrenamiento:  $loss = 0.0030$ .
- Evaluación con los últimos 12 meses:  $RMSE = 0.1394334$ .




Figure: Pérdida durante el entrenamiento del modelo

# Validación del Modelo

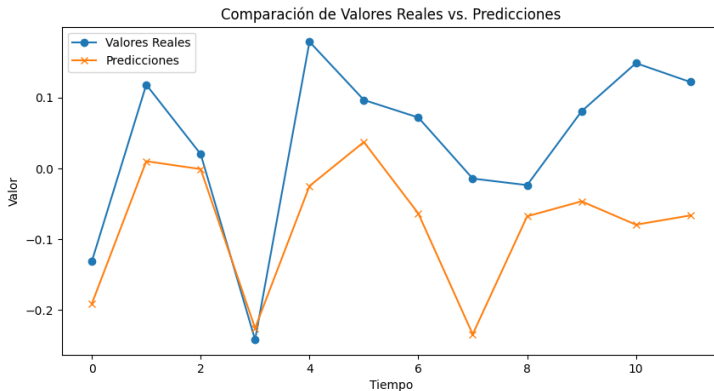


Figure: Validación de los últimos 12 valores

# Predicciones

- Modelo reentrenado con la muestra total.
- Predicciones para los próximos 6 periodos.




Figure: Predicciones para los próximos 6 periodos

# Predicción




Figure: Predicciones completas para los próximos 6 periodos

# Comparación de Modelos

- Comparación del desempeño de ARIMA-GARCH y la red neuronal.
- Análisis de errores y capacidad predictiva.
- Visualización de predicciones.



# Comparación de los modelos

<b>Modelo</b>	<b>RMSE</b>
ARMA-GARCH	0.1386556
Red Neuronal	0.1394334

Table: Comparación de RMSE entre modelos

# Conclusiones y Trabajo Futuro

- Resumen de hallazgos.
- Limitaciones del enfoque.
- Posibles mejoras y futuras investigaciones.