



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA

**Departamento de Estadística**  
**Series de tiempo univariadas**  
**Tarea 2**  
**01 de febrero - 2025**

Jhon Alejandro Ramírez Daza

jramirezda@unal.edu.co

---

## **1. Punto 1**

Consiga dos series de diferente periodicidad (por ejemplo: Una mensual y otra trimestral, series semanales, diarias o intradía son aceptables aunque más difíciles de modelar en la práctica). Documentar en dos párrafos la forma exacta de construcción de cada serie, esto es fuente, procedimiento, unidades de medida y otra información que consideren relevante. Brevemente aclare el interés suyo o de algún usuario en modelar y/o pronosticar dichas series. Presente las gráficas de cada una de estas dos series y describa brevemente la dinámica de cada serie. El número de datos debe incluir al menos desde 1970 para series anuales, desde 1980 para bimestrales y para trimestrales, desde enero de 1986 en el caso de mensuales; desde 1990 en caso semanal y desde 2001 en el diario.

Para este ejercicio se usaron las siguientes series de tiempo:

Producción anual de Ferrari, en la que se recopila anualmente cuantas unidades se producían de automóviles Ferrari al año, empezando desde 1947 y hasta el año 2023, siendo Ferrari una importantísima empresa de autos de lujo y ser tan escasas las unidades producidas de forma anual puede resultar importante saber a posibles compradores cuantas unidades disponibles podrían producirse en años posteriores, estos datos fueron recopilados por el Ferrari Club España con información dada por Ferrari.

El gráfico de la serie de tiempo es el siguiente:




Figura 1: Producción anual Ferrari

En la figura 1 notamos como la cuenta con una tendencia que parece a simplista estocástica, no presenta a simple vista problemas de volatilidad, ni comportamientos estacionales.

Cantidad diaria de manchas solares contadas por SILSO, Observatorio Real de Bélgica, Bruselas. originalmente este dataset cuenta con datos desde 1850 hasta 2024 pero solo vamos a tener en cuenta los valores desde el año 2000, ya que al ser datos diarios son una gran cantidad de observaciones, por lo que nos concentraremos en los datos mas recientes, puede resultar de mucha utilidad conocer cual es el comportamiento de estas manchas solares para conocer como se relacionan estas con la actividad solar por ejemplo, y con esta información tener predicciones de el clima solar proximo.

la gráfica de esta serie de tiempo es la siguiente:




Figura 2: Conteo de manchas solares diarias

De la gráfica 2 vemos que no es muy claro a simple vista si existe un nivel base, esto dado a que en la gráfica se puede ver algún estacionalidad o un ciclo, tampoco se ven problemas con volatilidad.

## 2. Punto 2

Trabajando en Excel u otro programa (R o Python), calcule y presente gráficamente dos promedios móviles de algún orden para cada una de las series de la pregunta 1. Comente brevemente las diferencias entre ellas y la serie original.

Empecemos con los datos de producción de Ferrari, se usaron ventanas de 3,5 y 10 años para la creación de los promedios móviles en la gráfica 3.




Figura 3: Promedios móviles producción Ferrari

De el gráfico 3 vemos que perdemos menos datos al usar 3 años pero la gráfica conserva mucha de la dinámica de la serie original, por otro lado el promedio móvil usando 10 años muestra de forma mas clara la tendencia que posee la serie original sin embargo se pierden bastantes datos al no contar con demasiados por ser una serie anual.

Por otro lado para la serie de observaciones de manchas solares se usaron 30, 180 y 365 días como ventana para realizar estos promedios móviles, dando como resultado la gráfica 4:




Figura 4: Promedios móviles manchas solares observadas diarias

De la gráfica 4 podemos ver que con tan solo 30 días se ajusta fuertemente a la curva aunque con menor dispersión, mientras que con 180 y 365 días se puede ver de forma mas suave la tendencia que presenta la serie, también es posible ver de forma más clara el ciclo o estacionalidad.

### 3. Punto 3

Repita el siguiente ejercicio numérico tres veces. Genere  $n = 500$  observaciones a partir del modelo ARMA dado por:

$$x_t = 0,9x_{t-1} + w_t - 0,9w_{t-1}$$

con  $w_t \sim iidN(0, 1)$ . Dibuje los datos simulados, calcule la ACF y la PACF de muestra de los datos simulados y ajuste un modelo ARMA(1, 1) a los datos. ¿Qué sucedió y cómo explica los resultados?

los resultados graficos se presentan a continuación:

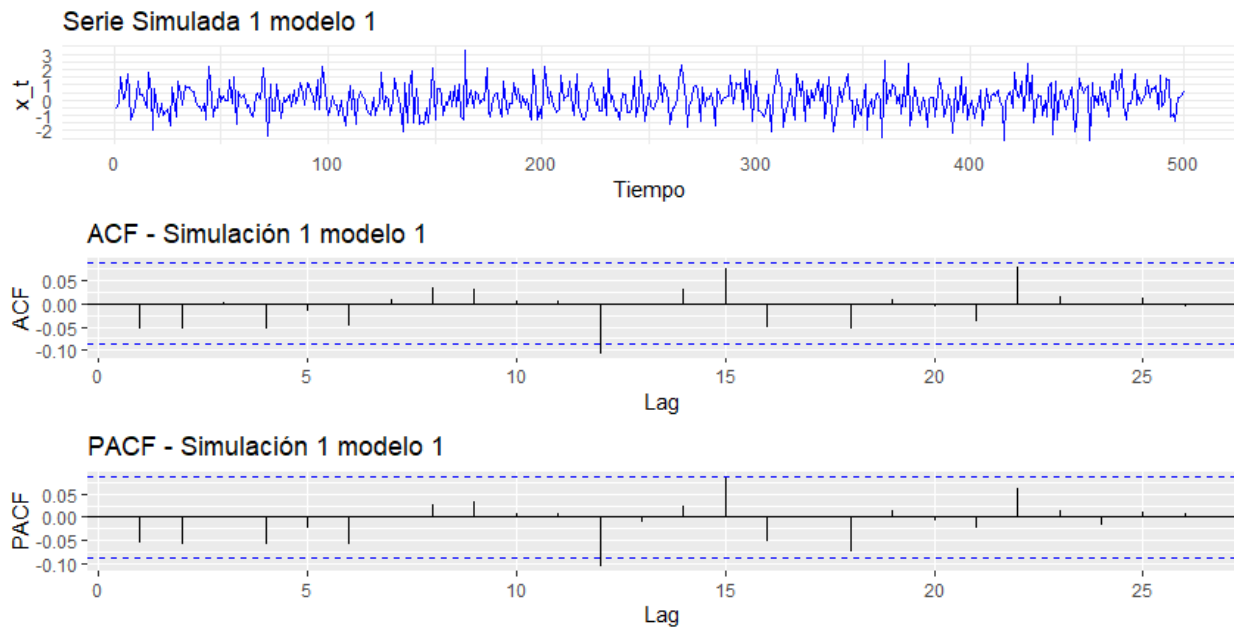


Figura 5: Simulación 1 modelo 1




Figura 6: Simulación 2 modelo 1

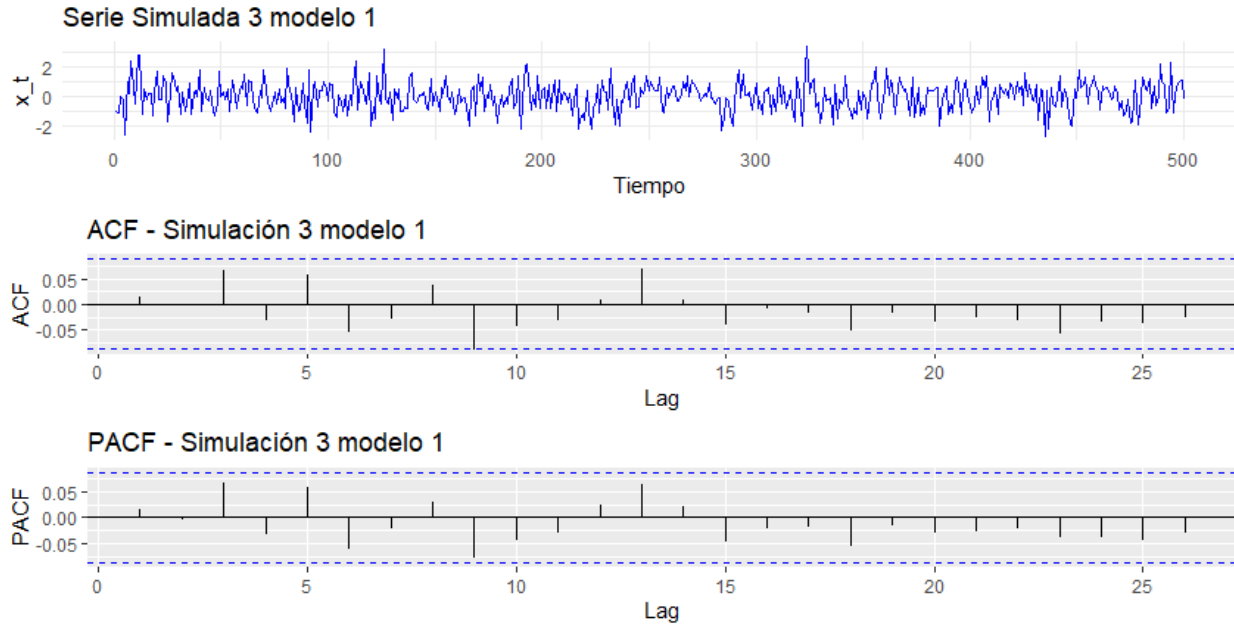


Figura 7: Simulación 3 modelo 1

Con las 3 simulaciones se realizaron los graficos fijándonos en los graficos de las series vemos que como es esperable por la simulación las 3 tienen como nivel base el 0 dispersiones similares aunque en el gráfico 6 se tiene un eje y más extenso esto por algunos datos mas grandes que se simularon.

Por otro lado vemos que tanto para los graficos ACF como PACF no se ve ningún comportamiento, como era de esperarse, solo se dio que en la simulación 1 se presento un resago apenas significativo en el resago 12 tan para el gráfico ACF como el PACF, como se ve en 5.

por otro lado los resultados del ajuste del modelo  $ARMA(1,1)$  para cada una de las simulaciones se ve resumido en la siguiente tabla 1

Simulación	AR1 Estimado	MA1 Estimado	$\sigma^2$ Estimado	AIC
1	0.7135	-0.7794	0.936	1393.91
2	-0.0012	-0.0012	1.02	1436.78
3	0.6188	-0.5996	0.9832	1418.46

Cuadro 1: Resumen de las estimaciones de los modelos  $ARMA(1,1)$  para las tres simulaciones.

Con respecto a la table 1 vemos que con los datos simulados 1 se estimaron de forma más cercana a la realidad los parámetros tanto de la parte  $AR$  como de la parte  $MA$  de igual forma la varianza estimada fue bastante cerca, por otro lado los datos simulados 2 llevaron a unos parámetros bastante alejados de los valores reales tanto de el parámetro  $AR$  como del parámetro  $MA$  mientras que la estimación de la varianza también estuvo muy aceptada.

En este caso no resulta de utilidad comparar los AIC ya que los 3 son igual modelo, pero los datos simulados 1 llevaron a un AIC más bajo.

Repita el ejercicio con los dos modelos siguientes:

$$x_t = 0,2x_{t-1} + 0,55x_{t-2} + w_t, w_t \sim iidN(0, \sigma^2 = 2,25)$$

$$x_t = w_t + 0,9w_{t-1} - 0,8w_{t-2} - 0,8w_{t-3}, w_t \sim iidN(0, \sigma^2 = 9)$$

Como vemos el segundo modelo corresponde a un modelo  $AR(2)$  puro y el tercer modelo a un  $MA(3)$  puro, realizamos 3 simulaciones de cada uno igual que en el caso anterior, empecemos por el modelo 2:




Figura 8: Simulación 1 modelo 2






Figura 9: Simulación 2 modelo 2




Figura 10: Simulación 3 modelo 2

Los graficos de las 3 simulaciones resultan sumamente parecidos, no notandose una gran diferencia entre ellos, de igual manera en los 3 graficos ACF se nota un decreimiento lento, mientras que en los tres PACF se ve claramente un truncamiento en 2 lo que corresponde con lo esperado para un modelo  $AR(2)$ , de hecho por los graficos resultaría posible pensar en el valor estimado de los coeficientes auto regresivos.

Ahora los resultados del ajuste del modelo se presentan a continuación :

Simulación	AR1 Estimado	AR2 Estimado	$\sigma^2$ Estimado	AIC
1	0.1951	0.5301	2.075	1792.71
2	0.1536	0.5355	2.318	1848.13
3	0.1756	0.5770	2.367	1858.64

Cuadro 2: Resumen de las estimaciones de los modelos ARMA(2,0) para las tres simulaciones.

En este caso como vemos en la tabla ?? los tres modelos resultantes para cada muestra resulta sumamente parecido en términos de todas las estimaciones tanto de los coeficientes autor regresivos como la varianza.

Ahora veamos el modelo 3:




Figura 11: Simulación 1 modelo 3

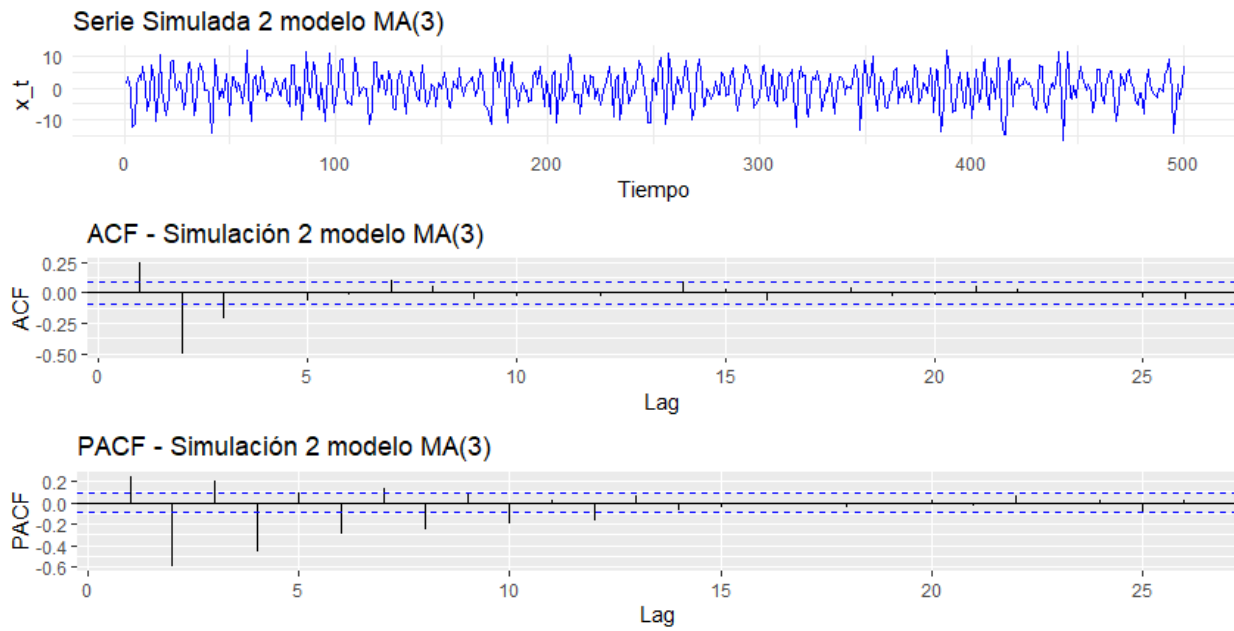


Figura 12: Simulación 2 modelo 3




Figura 13: Simulación 3 modelo 3

De los anteriores graficos notamos un comportamiento similar de forma completamente esperable, por otra parte en los graficos ACF se puede notar el mismo comportamiento un truncamiento en 3 que corresponde con el comportamiento de un modelo  $MA(3)$  puro, mientras que en las PACF se denota un decaimiento.

El resumen del comportamiento del ajuste del modelo se ve a continuación en la siguiente tabla:

Simulación	MA1 Estimado	MA2 Estimado	MA3 Estimado	$\sigma^2$ Estimado	AIC
1	0.8959	-0.7792	-0.7772	8.252	2489.02
2	0.8634	-0.8100	-0.7678	9.581	2563.62
3	0.8879	-0.8068	-0.8008	9.582	2563.99

Cuadro 3: Resumen de las estimaciones de los modelos ARMA(0,3) para las tres simulaciones.

Vemos en la table 3 los valores estimados de los coeficientes y la varianza resultan muy buenos y muy cercanos sin importar la muestra con la que fueron estimados.

## 4. Punto 4

Para cada una de las cuatro series de tiempo de la Hoja1 del libro archivo Excel llamado "HW02-DatosPunto4.xls", haciendo uso de la metodología de Box-Jenkins: (i) estime el modelo ARMA correspondiente, (ii) evalúe los residuales del modelo y (iii) realice pronósticos hasta el horizonte  $h = 6$ . Por último, determine si el proceso estimado es estacionario e invertible.

Para lo siguiente presentamos para cada una de las series su gráfico junto con las gráficas ACF y PACF:

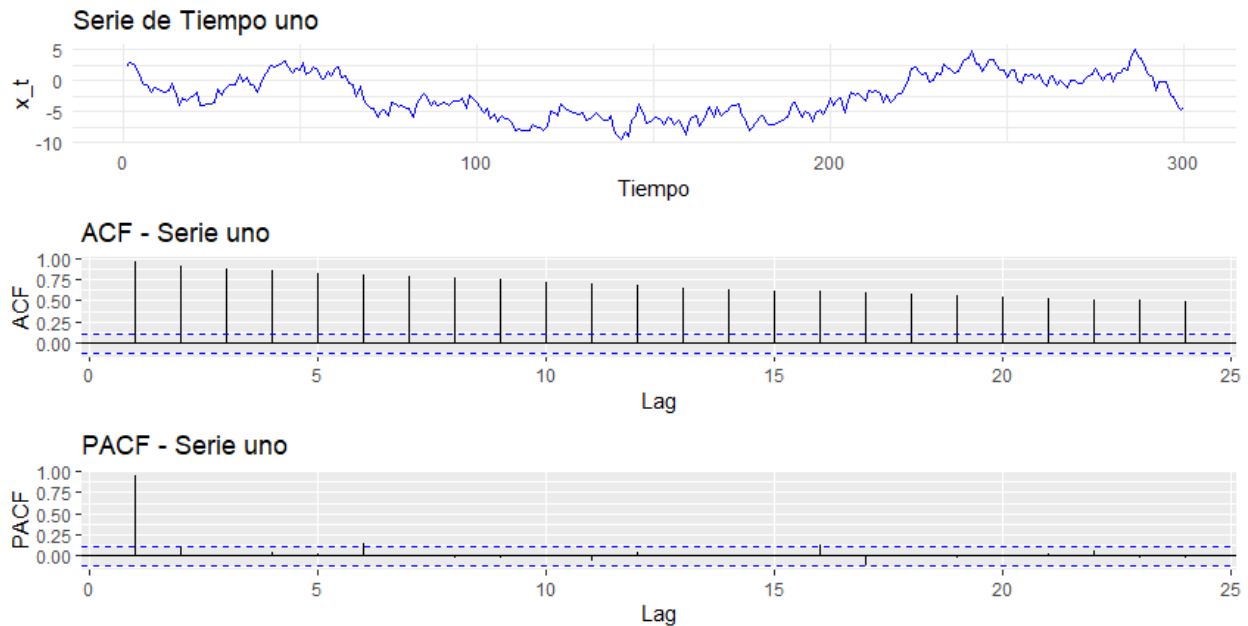


Figura 14: Serie uno

Para esta primera serie como podemos por en el gráfico 14 no se evidencian problemas de volatilidad y parece estar sobre un valor constante, también es distinguible un comportamiento en la función ACF donde decrece lentamente, mientras que en la función PACF se ve un bastante claro truncamiento en 1 lo que nos da el indicio de que podríamos estar ante un modelo  $AR(1)$  pero eso se determinara más adelante.




Figura 15: Serie dos

Para esta primera serie como podemos por en el gráfico 15 no se evidencian problemas de volatilidad y parece estar sobre un valor constante, también es distinguible un comportamiento en la función PACF donde decrece lentamente, mientras que en la función ACF se ve un bastante claro truncamiento en 1 lo que nos da el indicio de que podríamos estar ante un modelo  $MA(1)$  pero eso se determinara más adelante.

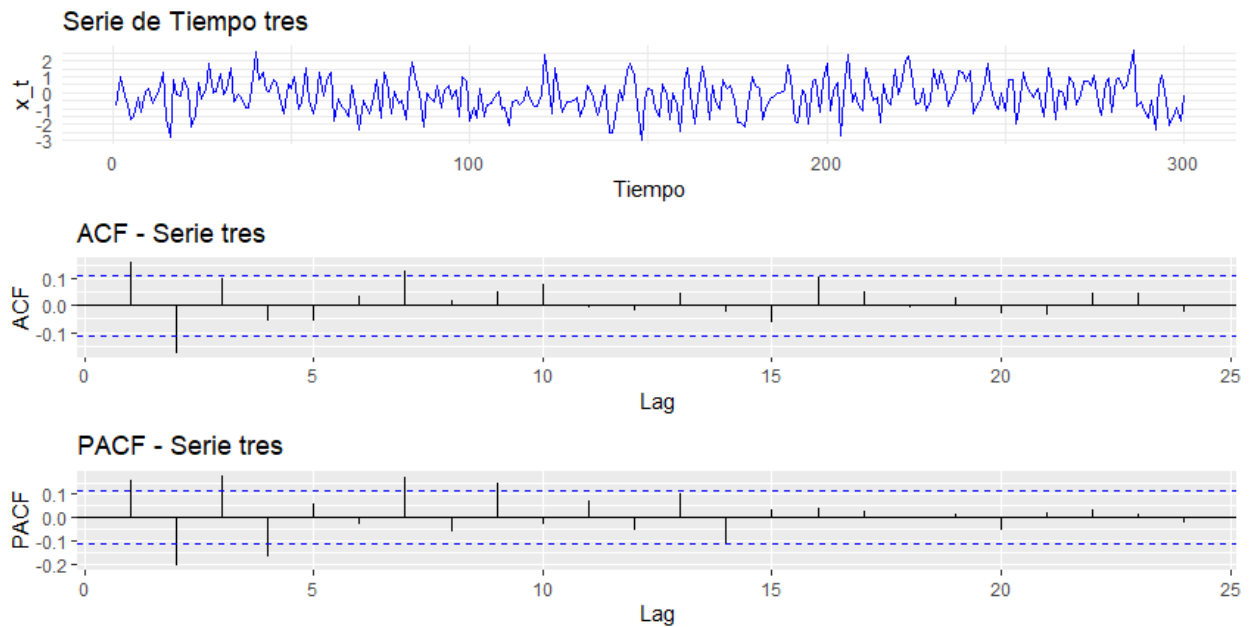


Figura 16: Serie tres

Para esta primera serie como podemos por en el gráfico 16 no se evidencian problemas de volatilidad y parece estar sobre un valor constante, en este caso no se puede decir con seguridad si existe algún comportamiento en las funciones ACF y PACF por lo que desde este gráfico aun no podemos aventurarnos a tener algún candidato a modelo *ARMA*.

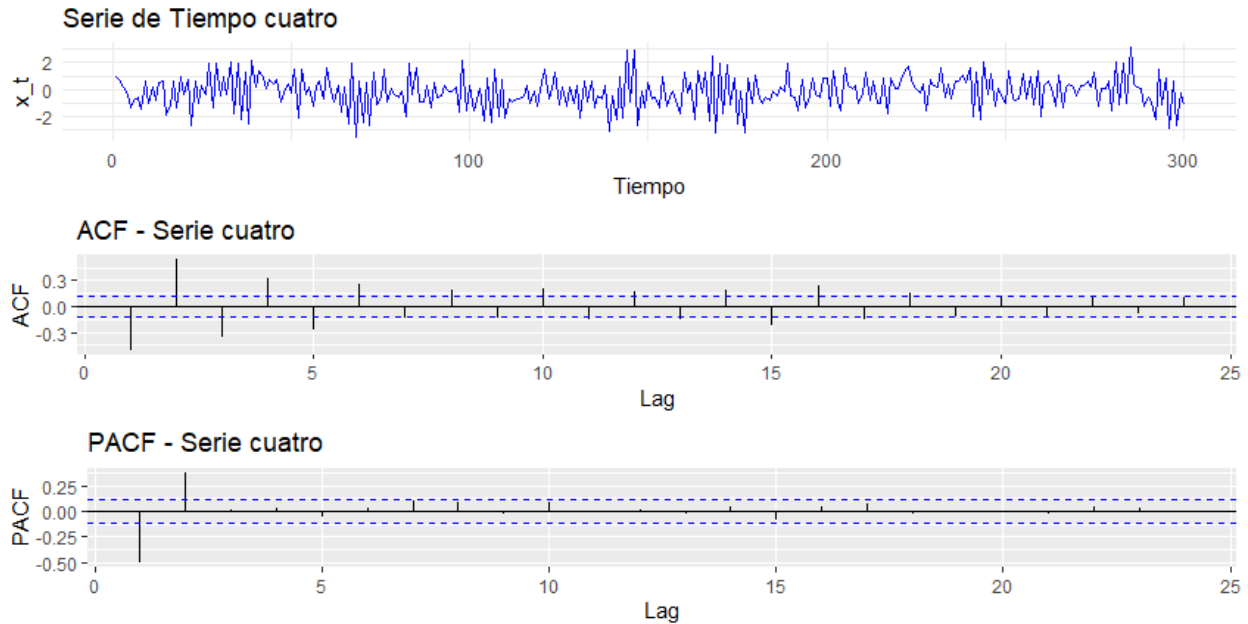


Figura 17: Serie cuatro

Para esta primera serie como podemos por en el gráfico 17 no se evidencian problemas de volatilidad y parece estar sobre un valor constante, también es distinguible un comportamiento en la función ACF donde decrece lentamente, mientras que en la función PACF se ve un bastante claro truncamiento en 2 lo que nos da el indicio de que podríamos estar ante un modelo *AR*(2) pero eso se determinara más adelante.

Con lo anterior con cada una de las 4 series se utilizo la función EACF para ver por este método el grado con el que poder ajustar en modelo *ARMA*(*p*, *q*) a cada una de estas series, por otro lado también se utilizo la función autoarima para realizar las misma tarea.

- Los resultados de estos dos métodos para para la serie uno es un modelo *ARMA*(1,1) esto tanto gráficamente por medio de la función EACF como por medio de la función autoarima restringiendo el valor de la diferencia regular a 0, bajo este modelo se estimaron el siguiente modelo:

$$x_t = -2,2012 + 0,9669x_{t-1} + w_t - 0,1393w_{t-1}$$

con esto vemos que el modelo cuenta con media, en  $-2,2012$  y con estos modelos podemos, pasar a la evaluación de residuales donde al aplicarles la pruna Ljung-Box llegamos a un p-valor de 0,42 por lo que no tenemos suficiente evidencia estadística para rechazar la hipótesis de diferencia de correlaciones temporales entre los resagos con lo que verificamos el supuesto de covarianza entre los errores. por otro lado veamos la siguiente gráfica 18 de evaluación de los residuales:




Figura 18: Evaluación residuales serie uno

Con la anterior gráfica 18 vemos como los residuales parecen tener un buen valor medio en 0 y comparados con la distribución normal estándar cumplen de forma razonable el supuesto de normalidad que se usa para la estimación de los parámetros por máxima verosimilitud.

Con lo anterior veamos un gráfico de los pronósticos:




Figura 19: Pronósticos serie uno

por ultimo al usar el polinomio al que se llego anteriormente y calculando sus raíces llegamos a la conclusión de que el modelo es tanto estacionario como invertible.

- Los resultados de estos dos métodos para para la serie dos es un modelo  $MA(1)$  esto tanto gráficamente por medio de la función EACF como por medio de la función autoarima restringiendo el valor de la diferencia regular a 0, bajo este modelo se estimaron el siguiente modelo:

$$x_t = -0,2767 + 0,9099w_{t-1} + w_t$$

con esto vemos que el modelo cuenta con media, en  $-0,2767$  y con estos modelos podemos, pasar a la evaluación de residuales donde al aplicarles la pruna Ljung-Box llegamos a un p-valor de 0,327 por lo que no tenemos suficiente evidencia estadística para rechazar la hipótesis de diferencia de correlaciones temporales entre los resagos con lo que verificamos el supuesto de covarianza entre los errores. por otro lado veamos la siguiente gráfica 20 de evaluación de los residuales:

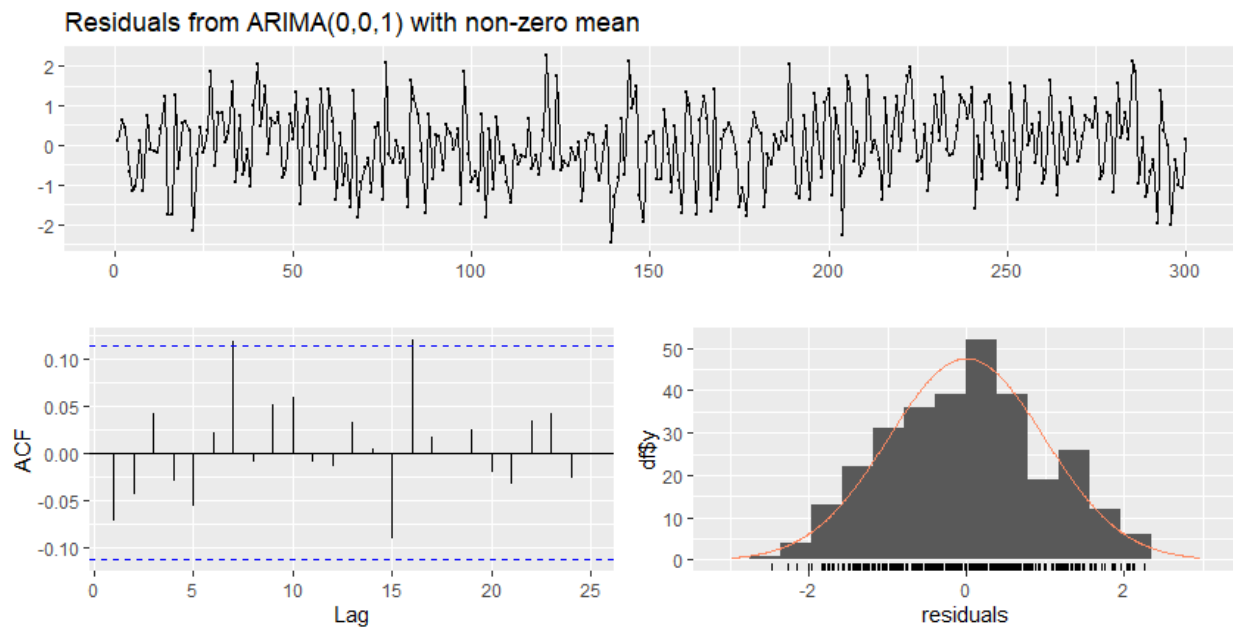


Figura 20: Evaluación residuales serie dos

Con la anterior gráfica 20 vemos como los residuales parecen tener un buen valor medio en 0 y comparados con la distribución normal estándar cumplen de forma razonable el supuesto de normalidad que se usa para la estimación de los parámetros por máxima verosimilitud.

Con lo anterior veamos un gráfico de los pronósticos:






Figura 21: Pronósticos serie dos

por ultimo al usar el polinomio al que se llego anteriormente y calculando sus raíces llegamos a la conclusión de que el modelo es tanto estacionario como invertible.

- Los resultados de estos dos métodos para para la serie tres es un modelo  $ARMA(1,2)$  esto tanto gráficamente por medio de la función EACF como por medio de la función autoarima restringiendo el valor de la diferencia regular a 0, bajo este modelo se estimaron el siguiente modelo:

$$x_t = -0,1876 - 0,4194x_{t-1} + w_t - 0,7560w_{t-1} - 0,1444w_{t-2}$$

con esto vemos que el modelo cuenta con media, en  $-0,1876$  y con estos modelos podemos, pasar a la evaluación de residuales donde al aplicarles la pruna Ljung-Box llegamos a un p-valor de 0,3226 por lo que no tenemos suficiente evidencia estadística para rechazar la hipótesis de diferencia de correlaciones temporales entre los resagos con lo que verificamos el supuesto de covarianza entre los errores. por otro lado veamos la siguiente gráfica 22 de evaluación de los residuales:




Figura 22: Evaluación residuales serie tres

Con la anterior gráfica 22 vemos como los residuales parecen tener un buen valor medio en 0 y comparados con la distribución normal estándar cumplen de forma razonable el supuesto de normalidad que se usa para la estimación de los parámetros por máxima verosimilitud.

Con lo anterior veamos un gráfico de los pronósticos:




Figura 23: Pronósticos serie tres

por ultimo al usar el polinomio al que se llego anteriormente y calculando sus raíces llegamos a la conclusión de que el modelo es tanto estacionario como invertible.

- Los resultados de estos dos métodos para para la serie cuatro es un modelo  $AR(2)$  esto tanto gráficamente por medio de la función EACF como por medio de la función autoarima restringiendo el valor de la diferencia regular a 0, bajo este modelo se estimaron el siguiente modelo:

$$x_t = -0,1714 + -0,3131x_{t-1} + 0,3763x_{t-2} + w_t$$

con esto vemos que el modelo cuenta con media, en  $-0,1714$  y con estos modelos podemos, pasar a la evaluación de residuales donde al aplicarles la pruna Ljung-Box llegamos a un p-valor de 0,4069 por lo que no tenemos suficiente evidencia estadística para rechazar la hipótesis de diferencia de correlaciones temporales entre los resagos con lo que verificamos el supuesto de covarianza entre los errores. por otro lado veamos la siguiente gráfica 24 de evaluación de los residuales:

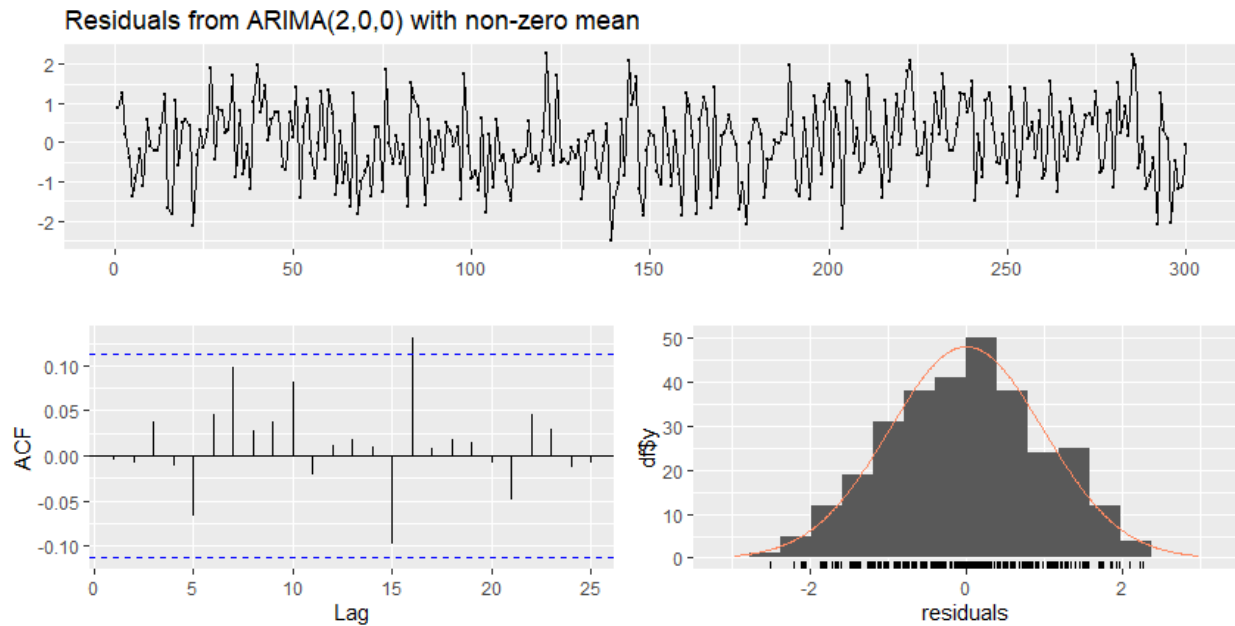


Figura 24: Evaluación residuales serie cuatro

Con la anterior gráfica 24 vemos como los residuales parecen tener un buen valor medio en 0 y comparados con la distribución normal estándar cumplen de forma razonable el supuesto de normalidad que se usa para la estimación de los parámetros por máxima verosimilitud.

Con lo anterior veamos un gráfico de los pronósticos:

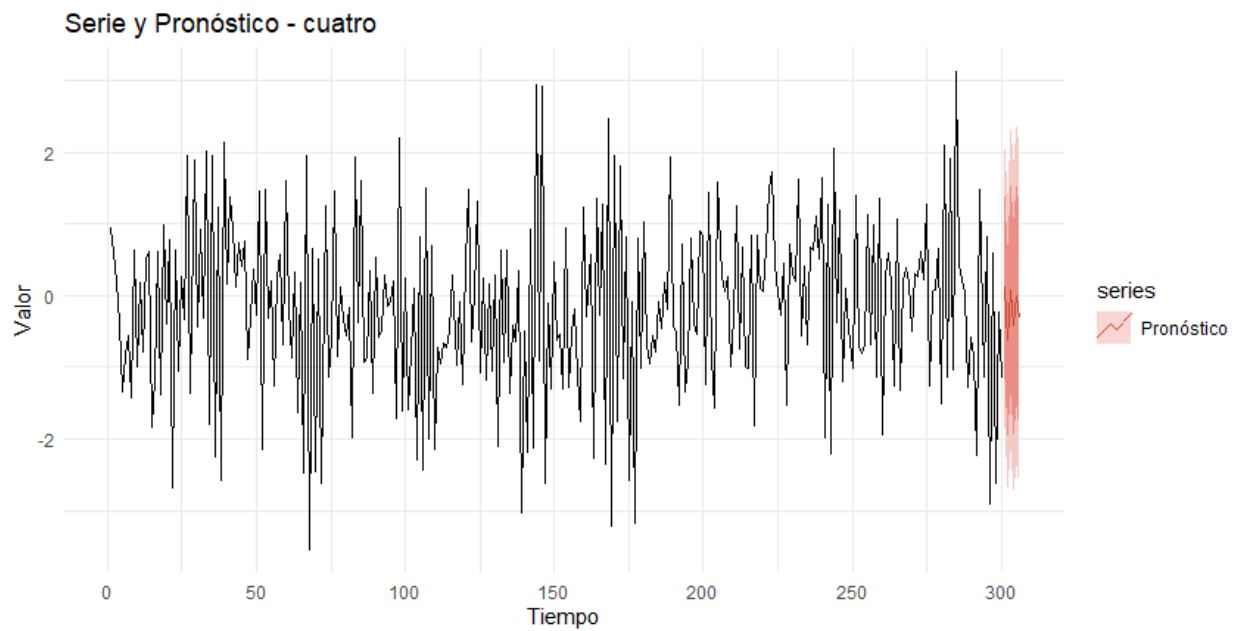


Figura 25: Pronósticos serie cuatro

por ultimo al usar el polinomio al que se llego anteriormente y calculando sus raíces llegamos a la conclusión de que el modelo es tanto estacionario como invertible.

## Anexos

```

1 ##taller 2 jramirezda
2 #cargar paquetes
3 # Crear un dataframe con los datos
4 produccion <- data.frame(
5   A o = 1947:2023,
6   Unidades = c(3, 5, 21, 26, 33, 44, 57, 58, 61, 81, 113, 183, 248, 306, 441, 493, 589, 654,
7     740, 665, 706, 729, 619, 928,
8     1246, 1844, 1772, 1436, 1337, 1426, 1798, 1939, 2221, 2470, 2565, 2209, 2366,
9     2842, 3288, 3640, 3902, 4001,
10    3821, 4293, 4487, 3384, 2345, 2671, 3144, 3350, 3518, 3652, 3669, 3946, 4305,
11    4276, 4238, 4975, 5409, 5671,
12    6465, 6587, 6250, 6573, 7195, 7405, 7000, 7255, 7664, 8014, 8398, 9251,
13    10131, 9119, 11115, 13221, 13663)
14 )
15 # Crear un objeto de serie de tiempo
16 ts_produccion <- ts(produccion$Unidades, start = 1947, frequency = 1)
17 # Graficar la serie de tiempo
18 library(ggplot2)
19 ggplot(produccion, aes(x = A o, y = Unidades)) +
20   geom_line(color = "blue") +
21   geom_point(color = "red") +

```

```

20 labs(title = "Producción Anual de Unidades de ferraris.",
21       x = "Año",
22       y = "Unidades Producidas") +
23 theme_minimal()
24
25 # Cargar y filtrar los datos de manchas solares
26 library(readr)
27 manchas_solares <- read_csv("daily_sunspots_time_series_1850-01_2024-05.csv")
28 manchas_solares <- manchas_solares %>% select(date, counts) %>% filter(date >= "2000-01-01")
29
30 # Convertir a serie de tiempo
31 ts_manchas <- ts(manchas_solares$counts, start = c(2000, 1), frequency = 365)
32
33 # Graficar la serie de tiempo de manchas solares
34 ggplot(manchas_solares, aes(x = date, y = counts)) +
35   geom_line(color = "blue") +
36   geom_point(color = "red", size = 0.5) +
37   labs(title = "Manchas Solares Diarias",
38        x = "Fecha",
39        y = "Conteo de Manchas Solares") +
40   theme_minimal()
41
42
43 ###promedios moviles
44
45 # Calcular promedios móviles
46 manchas_solares <- manchas_solares %>%
47   mutate(
48     MA5 = rollmean(counts, k = 30, fill = NA, align = "right"),
49     MA10 = rollmean(counts, k = 180, fill = NA, align = "right"),
50     MA15 = rollmean(counts, k = 365, fill = NA, align = "right")
51   )
52 produccion <- produccion %>%
53   mutate(
54     MA3 = rollmean(Unidades, k = 3, fill = NA, align = "right"),
55     MA4 = rollmean(Unidades, k = 5, fill = NA, align = "right"),
56     MA5 = rollmean(Unidades, k = 10, fill = NA, align = "right")
57   )
58
59 # Graficar la serie de tiempo de manchas solares con promedios móviles
60 ggplot(manchas_solares, aes(x = date)) +
61   geom_line(aes(y = counts, color = "Original")) +
62   geom_line(aes(y = MA5, color = "MA 30 días")) +
63   geom_line(aes(y = MA10, color = "MA 180 días")) +
64   geom_line(aes(y = MA15, color = "MA 365 días")) +
65   labs(title = "Manchas Solares Diarias con Promedios Móviles",
66        x = "Fecha",
67        y = "Conteo de Manchas Solares") +
68   theme_minimal() +
69   scale_color_manual(values = c("Original" = "aquamarine", "MA 30 días" = "red", "MA 180
70     días" = "green", "MA 365 días" = "purple"))
71
72 # Graficar la serie de tiempo de producción con promedios móviles
73 ggplot(produccion, aes(x = Año)) +

```

```

73 geom_line(aes(y = Unidades, color = "Original")) +
74 geom_line(aes(y = MA3, color = "MA 3 a os")) +
75 geom_line(aes(y = MA4, color = "MA 5 a os")) +
76 geom_line(aes(y = MA5, color = "MA 10 a os")) +
77 labs(title = "Producci n Anual con Promedios M viles",
78       x = "A o",
79       y = "Unidades Producidas") +
80 theme_minimal() +
81 scale_color_manual(values = c("Original" = "aquamarine", "MA 3 a os" = "red", "MA 5 a os"
82                               " = "green", "MA 10 a os" = "purple"))
83
84 # punto 3
85 library(forecast)
86 library(ggplot2)
87 library(tseries)
88 library(gridExtra)
89
90 set.seed(123) # Fijar semilla para reproducibilidad
91 n <- 500      # N mero de observaciones
92 simulations <- list()
93 #arma1,1
94 for (i in 1:3) {
95   # Simulaci n del modelo ARMA(1,1)
96   ar1 <- 0.9
97   ma1 <- -0.9
98   Wt <- rnorm(n, mean = 0, sd = 1)
99   xt <- numeric(n)
100   xt[1] <- Wt[1]
101
102   for (t in 2:n) {
103     xt[t] <- ar1 * xt[t - 1] + Wt[t] + ma1 * Wt[t - 1]
104   }
105
106   # Guardar resultados
107   simulations[[i]] <- xt
108
109   # Gr fico de la serie simulada
110   p1 <- ggplot(data.frame(t = 1:n, x = xt), aes(x = t, y = x)) +
111     geom_line(color = "blue") +
112     labs(title = paste("Serie Simulada", i,"modelo 1"), x = "Tiempo", y = "x_t") +
113     theme_minimal()
114
115   # ACF y PACF
116   p2 <- ggAcf(xt) + ggtitle(paste("ACF - Simulaci n", i,"modelo 1"))
117   p3 <- ggPacf(xt) + ggtitle(paste("PACF - Simulaci n", i, "modelo 1"))
118
119   # Ajuste del modelo ARMA(1,1)
120   modelo_ajustado <- arima(xt, order = c(1, 0, 1))
121   print(summary(modelo_ajustado))
122
123   # Mostrar gr ficos
124   grid.arrange(p1, p2, p3, nrow = 3)
125 }

```

```

126 #ar 2
127 for (i in 1:3) {
128   # Simulaci n del modelo AR(2)
129   ar1 <- 0.2
130   ar2 <- 0.55
131   Wt <- rnorm(n, mean = 0, sd = sqrt(2.25))
132   xt <- numeric(n)
133   xt[1] <- Wt[1] # Correcci n del ndice inicial
134   xt[2] <- ar1 * xt[1] + Wt[2] # Definir segundo valor
135
136   for (t in 3:n) {
137     xt[t] <- ar1 * xt[t - 1] + ar2 * xt[t - 2] + Wt[t]
138   }
139
140   # Guardar resultados
141   simulations[[i]] <- xt
142
143   # Gr fico de la serie simulada
144   p1 <- ggplot(data.frame(t = 1:n, x = xt), aes(x = t, y = x)) +
145     geom_line(color = "blue") +
146     labs(title = paste("Serie Simulada", i, "modelo AR(2)"), x = "Tiempo", y = "x_t") +
147     theme_minimal()
148
149   # ACF y PACF
150   p2 <- ggAcf(xt) + ggtitle(paste("ACF - Simulaci n", i, "modelo AR(2)"))
151   p3 <- ggPacf(xt) + ggtitle(paste("PACF - Simulaci n", i, "modelo AR(2)"))
152
153   # Ajuste del modelo AR(2)
154   modelo_ajustado <- arima(xt, order = c(2, 0, 0))
155   print(summary(modelo_ajustado))
156
157   # Mostrar gr ficos
158   grid.arrange(p1, p2, p3, nrow = 3)
159 }
160
161 #ma 3
162 for (i in 1:3) {
163   # Simulaci n del modelo AR(2)
164   ma1 <- 0.9
165   ma2 <- -0.8
166   ma3 <- -0.8
167   Wt <- rnorm(n, mean = 0, sd = sqrt(9))
168   xt <- numeric(n)
169   xt[1] <- Wt[1] # Correcci n del ndice inicial
170   xt[2] <- ma1 * Wt[1] + Wt[2] # Definir segundo valor
171   xt[3] <- ma1 * Wt[2] +ma2* Wt[1] +Wt[3]
172
173   for (t in 4:n) {
174     xt[t] <- ma1 * Wt[t - 1] + ma2 * Wt[t - 2] +ma3* Wt[t-3] + Wt[t]
175   }
176
177   # Guardar resultados
178   simulations[[i]] <- xt
179

```

```

180 # Gráfico de la serie simulada
181 p1 <- ggplot(data.frame(t = 1:n, x = xt), aes(x = t, y = x)) +
182   geom_line(color = "blue") +
183   labs(title = paste("Serie Simulada", i, "modelo MA(3)"), x = "Tiempo", y = "x_t") +
184   theme_minimal()
185
186 # ACF y PACF
187 p2 <- ggAcf(xt) + ggtitle(paste("ACF - Simulación", i, "modelo MA(3)"))
188 p3 <- ggPacf(xt) + ggtitle(paste("PACF - Simulación", i, "modelo MA(3)"))
189
190 # Ajuste del modelo AR(2)
191 modelo_ajustado <- arima(xt, order = c(0, 0, 3))
192 print(summary(modelo_ajustado))
193
194 # Mostrar gráficos
195 grid.arrange(p1, p2, p3, nrow = 3)
196 }
197
198
199 #punto 3
200 library(forecast)
201 library(ggplot2)
202 library(tseries)
203 library(gridExtra)
204 library(readxl)
205 library(TSA) # Para la función EACF
206
207 # Cargar datos desde Excel
208 Datos <- read_excel("HW02-DatosPunto4.xls")
209
210 # Convertir las series en objetos de serie de tiempo
211 timeseries_list <- list(
212   uno = ts(Datos$serie1, frequency = 1),
213   dos = ts(Datos$serie2, frequency = 1),
214   tres = ts(Datos$serie3, frequency = 1),
215   cuatro = ts(Datos$serie4, frequency = 1)
216 )
217
218 plot_series <- function(series, series_name) {
219   n <- length(series)
220   df <- data.frame(t = 1:n, x = series)
221
222   # Gráfico de la serie de tiempo
223   p1 <- ggplot(df, aes(x = t, y = x)) +
224     geom_line(color = "blue") +
225     labs(title = paste("Serie de Tiempo", series_name), x = "Tiempo", y = "x_t") +
226     theme_minimal()
227
228   # Gráfico de ACF
229   p2 <- ggAcf(series) + ggtitle(paste("ACF - Serie", series_name))
230
231   # Gráfico de PACF
232   p3 <- ggPacf(series) + ggtitle(paste("PACF - Serie", series_name))
233

```



```

234 # Combinar los gr ficos en una sola figura
235 grid.arrange(p1, p2, p3, nrow = 3)
236 }
237
238 # Generar los gr ficos para cada serie de tiempo
239 for (i in seq_along(timeseries_list)) {
240   series_name <- names(timeseries_list)[i]
241   plot_series(timeseries_list[[i]], series_name)
242 }
243
244 ##arma
245 timeseries_results <- list()
246
247 for (name in names(timeseries_list)) {
248   ts_data <- timeseries_list[[name]]
249
250   # Identificaci n del modelo ARMA con EACF
251   print(paste("EACF para la serie:", name))
252   eacf_result <- eacf(ts_data)
253   print(eacf_result)
254
255   # Ajuste del modelo ARMA (sin diferenciaci n regular)
256   modelo_ajustado <- auto.arima(ts_data, d = 0, seasonal = FALSE)
257   print(paste("Modelo ajustado para:", name))
258   print(summary(modelo_ajustado))
259
260   # Evaluaci n de residuales
261   checkresiduals(modelo_ajustado)
262
263   # Pron sticos h=6
264   forecast_h <- forecast(modelo_ajustado, h = 6)
265   print(forecast_h)
266
267   # Graficar la serie original y el pron stico
268   p1 <- autoplot(ts_data) +
269     autolayer(forecast_h, series = "Pron stico", PI = TRUE) +
270     labs(title = paste("Serie y Pron stico -", name), x = "Tiempo", y = "Valor") +
271     theme_minimal()
272
273   # Evaluaci n de estacionariedad e invertibilidad
274   estacionario <- all(Mod(polyroot(c(1, -modelo_ajustado$coef[grepl("ar", names(modelo_ajustado$coef))])))) > 1)
275   invertible <- all(Mod(polyroot(c(1, modelo_ajustado$coef[grepl("ma", names(modelo_ajustado$coef))])))) > 1)
276
277   print(paste("La serie", name, "es estacionaria:", estacionario))
278   print(paste("La serie", name, "es invertible:", invertible))
279
280   # Guardar resultados
281   timeseries_results[[name]] <- list(
282     eacf = eacf_result,
283     modelo = modelo_ajustado,
284     forecast = forecast_h,
285     estacionario = estacionario,

```

```
286     invertible = invertible,  
287     plot = p1  
288 )  
289  
290 print(timeseries_results[[name]]$plot)  
291 }
```

Listing 1: Código de R para series de tiempo tarea 2